

Vision Transformers (ViT) e Classificação Visual

Da Tirania do Pixel ao Fatiamiento em Patches, Atenção Global e Regularização com CutMix

Etapa / Aula 04

Faculdade Infnet • Pós-Graduação em IA & Machine Learning

✦ Fatiamiento em Patches (16×16)

✦ Patch Embedding (Conv2D Stride)

✦ Token [CLS] & Position Embeddings

✦ O Dilema do Viés Indutivo

✦ Regularização com CutMix & Mixup

✦ Mapas de Atenção Rollout

A Tirania do Pixel e a Explosão da Autoatenção

Por que não podemos aplicar o mecanismo de atenção diretamente em cada pixel da imagem?

Simular Resolução de Imagem:

64 × 64 px

112 × 112 px

224 × 224 px


384 × 384 px

Complexidade Quadrática da Autoatenção: $O(N^2)$

Entrada Espacial 2D

Imagem: 224 × 224 pixels

Total de tokens se cada pixel for tratado como um token independente:



SEQUÊNCIA NLP TÍPICA
L ≈ 512 tokens

SEQUÊNCIA DESTA IMAGEM
N = 50.176

Colapso Computacional

Matriz de Atenção [N × N]

Cálculo de $\text{Softmax}(Q \cdot K^T / \sqrt{d})$ em escala de pixel puro:

Dimensões da Matriz de Atenção:

[50.176 × 50.176]

Operações por Cabeça:

~2.52 Bilhões de FLOPS

VRAM Só para a Matriz (Batch=1):

~9.4 GB de VRAM!

⚡ **Diagnóstico de Engenharia:** Tratar pixels isolados como tokens resulta em erro instantâneo de *CUDA Out of Memory (OOM)*. A visão computacional precisava urgentemente de uma forma de **discretizar a imagem em unidades semânticas maiores!**

O Dilema do Viés Indutivo: CNN vs Transformer

Premissas estruturais rígidas de localidade versus liberdade total de relações espaciais

Comparar Paradigmas:

Confronto Direto (Lado a Lado)

CNN: Viés Indutivo Forte

ViT: Atenção Global Livre


Trade-off: Suposições Rígidas vs Liberdade Total de Relações

Redes Convolucionais (CNN)


Desde LeNet (1998)

Viés Indutivo Forte (*Hard-Coded*)

A operação convolucional **impõe por design** duas premissas estruturais rígidas na imagem:



1. Localidade Estrita 2D
Apenas vizinhos imediatos (3x3)



2. Equivariância
Translação preservada

PREMISSA ESTRUTURAL

- **Localidade 2D:**
Pixels vizinhos formam arestas, texturas e partes anatômicas.
- **Equivariância Translacional:**
Um padrão visual é detectado em qualquer canto da imagem.

⚡ **Convergência com poucos dados**


- ✓ **Aprende rápido com poucos dados:** Não precisa reaprender que pixels vizinhos formam arestas e olhos.
- ✗ **Miopia Global:** O campo receptivo só se expande empilhando muitas camadas profundas.

Vision Transformer (ViT)

Dosovitskiy et al. (2020)

Viés Indutivo Fraco (*Quase Nulo*)

O Transformer **não sabe a priori** o que é uma imagem 2D; ele trata patches como tokens de texto livres:



Token Agregado

Atenção Cruzada Completa $O(N^2)$
Softmax($Q \cdot K^T / \sqrt{d}$) calcula correlação dinâmica

LIBERDADE RELACIONAL

- **Atenção Sem Limites:**
 P_1 conversa com P_4 tão diretamente quanto com P_2 .
- **Agnóstico à Grade 2D:**
A geometria espacial só é conhecida via Position Embeddings.

⚠ **Exige volumes massivos (JFT/21k)**

- ✓ **Alcance Global Imediato:** Qualquer parte da imagem pode conversar com qualquer outra desde o Bloco 1.
- ✗ **Fome de Dados Massiva:** Sem viés indutivo, precisa aprender relações espaciais puramente a partir de dados!

A Sacada dos Patches: 'An Image is Worth 16x16 Words'

Fatiando a matriz 2D contínua em uma sequência discreta de tokens visuais

💡 A Grande Sacada (Dosovitskiy et al., 2020): Substituir cada *palavra de texto* por um *patch 2D de pixels* (16×16).

Fórmula: $N = (H \cdot W) / P^2$






Imagem de Entrada
 $x \in \mathbb{R}^{(224 \times 224 \times 3)}$
150.528 valores contínuos

Fatiamento
Grade 14×14



196 Patches Espaciais
Cada patch: $16 \times 16 \times 3$
768 pixels por patch

Unroll 1D
Flattening



Sequência de Tokens Visuais
Tensor: [Batch, 197, 768]
Compatível com Transformer Encoder!



Lab 1: Simulador de Patches e Complexidade

Explore a relação entre resolução da imagem, tamanho do patch (P) e custo computacional

Resolução (H = W):

112px

224px

384px

Tamanho do Patch (P):

8×8


14×14

16×16

32×32

$N = (224 / 16)^2 = 196$

Grade Espacial: 14 × 14 (196 Patches 2D)



Cada célula é projetada para um vetor latente de dimensão $D = 768$

Impacto Computacional no Transformer

NÚMERO DE PATCHES (N)

196

+ 1 token [CLS] = 197

MATRIZ DE ATENÇÃO

38.809

197 × 197 elementos

MEMÓRIA ATENÇÃO (12 HEADS)

1.8 MB

por camada (Batch=1)

RELAÇÃO COM NLP

38%

do contexto de 512 do BERT

✓ **Ponto Ótimo de Engenharia:** Patch 16×16 gera 196 tokens para imagens 224×224. Esse tamanho permite que o Transformer processe a imagem inteira com custo computacional menor que uma sentença longa de NLP!

A Macro-Arquitetura do Vision Transformer (ViT)

O pipeline canônico completo: fatiamento, projeção linear, codificador e cabeça densa

Explorar
Estágios:

Visão Global
Completa

1. Fatiamento em Patches
(Input)

2. Projeção Linear (Patch
Embedding)

3. Transformer Encoder (+ Positional &
CLS)

4. Cabeça Densa de Classificação (Dense
Top)

Pipeline
Completo




Figure 8-11: The ViT architecture

ANÁLISE ANATÔMICA

A Arquitetura Canônica do Vision Transformer (ViT)

O diagrama clássico de Dosovitskiy et al. (ICLR 2021) demonstrando como um Transformer Encoder puro processa imagens com zero convoluções manuais intermediárias.

CORRESPONDÊNCIA COM O BERT EM NLP:

O Vision Transformer reutiliza com maestria 100% da engenharia do Transformer de NLP, alterando apenas a camada de entrada (Patch Embedding).

Referência Canônica: *An Image is Worth 16×16 Words* (Dosovitskiy et al., ICLR 2021)

Patch Embedding: Achatamento e Projeção Linear

Como transformar matrizes 3D de pixels em vetores latentes $D = 768$ via álgebra ou convolução strided

Perspectiva de Implementação:

1. Álgebra Linear (Flatten + Matriz E)

2. Truque de Engenharia (Conv2D com Stride=16)

Dimensão Latente: $D = 768$



Insight de Otimização GPU: A maioria das implementações na indústria (como PyTorch e TorchVision) utiliza `nn.Conv2d(3, 768, kernel_size=16, stride=16)` porque convoluções com stride aproveitam os núcleos tensoriais (Tensor Cores) com velocidade máxima.


Zero Perda
Algébrica

O Token [CLS] e os Position Embeddings 1D

Injeção de ordem espacial e o papel do vetor agregador global herdado do BERT

✿ Injeção Dupla: 1. Token [CLS] agregador de classe + 2. Position Embeddings para recuperar a ordem espacial 2D perdida.

Dimensão Resultante: [B, 197, 768]



Por que o Token [CLS]? Em vez de fazer uma média arbitrária de todos os patches (que pode diluir partes essenciais como a cabeça de um animal), o token [CLS] atua como um coletor dinâmico via autoatenção global.

Por que Embeddings 1D e não 2D? Os autores testaram embeddings baseados em coordenadas cartesianas (x, y) . No treino em larga escala, os vetores 1D aprenderam sozinhos a topologia bidirecional sem diferença estatística!

Anatomia do Bloco Transformer Encoder

Pre-LayerNorm, Multi-Head Self-Attention, conexões residuais e expansão 4× no MLP


Destacar Subcamada:

Bloco Completo

1. Pre-LN + Multi-Head Attention

2. Pre-LN + MLP (Expansão 4×)

Pre-LayerNorm Standard



Formulações Oficiais do Bloco

1. AUTOATENÇÃO RESIDUAL:

$$z'_{\ell} = \text{MSA}(\text{LN}(z_{\ell-1})) + z_{\ell-1}$$

2. MLP RESIDUAL (EXPANSÃO 4×):

$$z_{\ell} = \text{MLP}(\text{LN}(z'_{\ell})) + z'_{\ell}$$

- **Pre-LayerNorm:** A normalização é aplicada ANTES da atenção e do MLP, garantindo fluxo limpo de gradientes sem saturação.
- **Expansão 4× do MLP:** O vetor de dimensão \$768\$ é projetado linearmente para \$3072\$ com ativação GELU e depois rebaixado de volta para \$768\$.



Lab 2: Rastreador Dimensional de Tensores

Acompanhe passo a passo o formato exato dos tensores em cada etapa do forward pass do ViT

Passo 1

Passo 2

Passo 3

Passo 4

Passo 5

Passo 6

Passo 7

◀ Anterior

Próximo ▶

1. Imagem de Entrada

FORMATO DO TENSOR EM MEMÓRIA

[B, 3, 224, 224]

Lote de B imagens coloridas com altura e largura de 224 pixels e 3 canais de cor (RGB).

OPERAÇÃO PYTORCH EQUIVALENTE:

`x = images # Tensor float32 normalizado`

💡 RASTREIO DE DIMENSÕES:

Observe como a dimensão oculta **D = 768** permanece rigorosamente estável da etapa 2 à etapa 6. O Transformer preserva a dimensionalidade latente ao longo de todas as 12 camadas!

A Situação-Problema: A Fome de Dados do ViT

Por que treinar um Vision Transformer do zero em datasets moderados (ImageNet-1k) fracassa?

Regime de Pré-treino:


Curva Completa de Escala

1. ImageNet-1k (1,3M imagens)

2. ImageNet-21k (14M imagens)

3. JFT-300M (300M imagens)

Descoberta Chave do Artigo ViT



Causa-Raiz Teórica

Por que o ViT Falha com Poucos Dados?

Sem as convoluções forçando o modelo a olhar para pixels vizinhos, o ViT tem **graus de liberdade demais**. Em datasets com menos de 10 milhões de imagens, ele memoriza o ruído em vez de aprender a estrutura visual!

A GRANDE PERGUNTA DA INDÚSTRIA:

"Como treinar um Vision Transformer com alta acurácia quando **não temos 300 milhões de imagens** proprietárias da Google?"

→ Resposta: Regularização Pesada com CutMix e Mixup!

A Sacada do CutMix: Quebrando o Overfitting

Forçando o ViT a correlacionar múltiplos patches sem gerar artefatos artificiais nos pixels

Evolução da Regularização:


1. Imagem Pura

2. Cutout (Blackout)

3. Mixup (Transparência)

4. CutMix (A Sacada!)

Padrão em ViT e DeiT



CutMix: O Melhor dos Dois Mundos (Yun et al., 2019)

Corta uma caixa delimitadora de uma imagem e COLA sobre outra! Todos os pixels permanecem naturais e nítidos, enquanto os rótulos são combinados proporcionalmente à área!

🎯 POR QUE O CUTMIX SALVA O VISION TRANSFORMER?

Como o ViT enxerga a imagem como uma sequência de **patches independentes**, o CutMix substitui blocos inteiros de patches. Isso obriga a autoatenção a correlacionar múltiplos sinais visuais em paralelo, impedindo que o modelo memorize um único patch!

Interpretabilidade: Mapas de Atenção do ViT

Visualizando a autoatenção entre o token [CLS] e os patches espaciais (Attention Rollout)


Profundidade da Atenção:

1. Camadas Iniciais (Bloco 1-3)

2. Camadas Intermediárias (Bloco 6-8)

3. Camadas Finais (Bloco 11-12)

Algoritmo: Attention Rollout



Foco Observado: **Objeto Chave (Máxima Saliência)**

Atenção Final (Rollout): Concentração Cirúrgica no Objeto

O token [CLS] foca quase 100% dos seus pesos nos traços distintivos que definem a classe, ignorando completamente o céu, grama ou fundo desnecessário!

Por que isso importa na prática?

Diferente de métodos como Grad-CAM em CNNs (que exigem gradientes retropropagados), no Vision Transformer a explicabilidade é **nativa do próprio mecanismo de atenção**! Podemos inspecionar a matriz de atenção diretamente durante o forward pass.



A Família ViT: Configurações, Parâmetros e Desempenho

Comparativo técnico entre variantes ViT-Base, ViT-Large, ViT-Huge, ResNet e ConvNeXt

Filtrar Arquiteturas:

Todos os Modelos

Apenas Família ViT

Linha CNN / Híbridos

Métricas ImageNet-1k (Top-1)

Modelo	Família	Camadas	Dim Oculta (D)	Cabeças	Patch Size	Parâmetros	GFLOPs	Top-1 Acurácia
ResNet-50	CNN	50	2048	—	—	25.6 M	4.1 G	76.1%
ResNet-152	CNN	152	2048	—	—	60.2 M	11.5 G	78.3%
ViT-Base / 32	VIT	12	768	12	32 × 32	88.2 M	4.4 G	77.9%
ViT-Base / 16 ★	VIT	12	768	12	16 × 16	86.6 M	17.6 G	81.2%
ViT-Large / 16 ★	VIT	24	1024	16	16 × 16	304.3 M	61.6 G	85.2%
ViT-Huge / 14	VIT	32	1280	16	14 × 14	632.0 M	167.3 G	88.5%
ConvNeXt-Base	CNN	36	1024	—	7 × 7	88.6 M	15.4 G	83.8%

💡 Padrão de Mercado: O ViT-Base/16 (86M parâmetros) é o cavalo de batalha da indústria, oferecendo equilíbrio perfeito entre velocidade e precisão.

★ Configurações Recomendadas



Lab 3: Explorador de Trade-offs (ViT vs CNN)

Compare acurácia, latência de inferência, uso de VRAM e throughput para tomada de decisão em produção

Cenário de Produção:

Dispositivo de Borda (Edge)

Servidor Nuvem (Padrão)

Acurácia Crítica (SOTA)

Decisão de Engenharia

RECOMENDAÇÃO ARQUITETURAL

ViT-Base / 16 (Fine-Tuned com CutMix) ou ConvNeXt-Base

Objetivo: Equilíbrio Ótimo entre Acurácia Top-1 (>82%) e Throughput

O ViT-Base com 86M de parâmetros atinge 81.2% a 84.5% no ImageNet, processando batches grandes em GPUs corporativas (A100, L4) com alta eficiência em Tensor Cores.

 **Regra de Ouro da Arquitetura:** Não existe modelo universalmente superior. Para datasets médios e hardware restrito, CNNs e híbridos dominam; para datasets massivos com suporte a paralelismo de tensores na nuvem, Vision Transformers são imbatíveis.

ACURÁCIA ESPERADA (TOP-1)

81.2% ~ 84.5%

LATÊNCIA DE INFERÊNCIA (GPU)

~22 ms

CONSUMO DE MEMÓRIA VRAM (INFERÊNCIA)

~3.2 GB

Quiz Interativo de Fixação

Teste seu domínio sobre fatiamento de patches, viés indutivo e regularização com CutMix

Fixação de Conceitos: Vision Transformers & CutMix

3 Questões de Fixação

1. Fatiamento de Patches: Em uma imagem 384×384 com patch 16×16 , qual é a quantidade de tokens na entrada do Transformer Encoder?

- ☐ A 384 tokens (um token por linha horizontal da imagem).
- ☐ B 577 tokens: 576 patches espaciais (24×24) somados a 1 token especial [CLS].
- ☐ C 197 tokens: o Transformer fixa o tamanho máximo de tokens em 197 independentemente da resolução da imagem.
- ☐ D 147.456 tokens: cada pixel RGB é tratado como um token individual de dimensão D.

2. Viés Indutivo: Por que o ViT puro tem pior desempenho que uma ResNet ao ser treinado do zero em datasets moderados (ImageNet-1k)?

- ☐ A Porque o ViT possui camadas convolucionais excessivamente profundas que dissipam o gradiente.
- ☐ B Porque o ViT tem viés indutivo fraco (não assume localidade 2D nem translação), exigindo dados massivos ou regularizações como CutMix para não memorizar ruído.
- ☐ C Porque a função de ativação GELU gera saturação assintótica nos tensores de patch.
- ☐ D Porque o token [CLS] descarta toda a informação espacial presente nos patches intermediários.

3. Mecânica do CutMix: Se a caixa recortada de uma classe B ocupa 30% da área sobreposta à classe A ($\lambda = 0.70$), qual é o alvo de treinamento?

- ☐ A O rótulo é binário: vence a classe A (100% classe A e 0% classe B) pois ela é a maioria da imagem.
- ☐ B Os pixels cortados são zerados com blackout preto e o alvo permanece inalterado.
- ☐ C Gera-se um rótulo suave (soft target): $\hat{y} = 0.70 \cdot y_A + 0.30 \cdot y_B$, e a perda Cross-Entropy pondera ambas as classes pela proporção de área.
- ☐ D A imagem combinada é descartada e o batch é reamostrado.