

Modelos ViT Avançados: DeiT, PVT, Swin Transformer & DINO

Revisão do ViT Canônico, Destilação com Tokens, Pirâmides Espaciais, Janelas Deslocadas e Auto-supervisão

Etapa / Aula 05

Faculdade Infnet • Pós-Graduação em IA & Machine Learning

✦ Revisão do ViT Canônico

✦ DeiT & Distillation Token

✦ PVT & Spatial-Reduction

✦ Swin & Shifted Windows

✦ DINO & Self-Supervision

✦ MAE & ConvNeXt

Revisão: A Engenharia do Pipeline Canônico do ViT

Rastreamento de Tensores: do fatiamento 2D à extração final pelo token [CLS]

REVISÃO ESSENCIAL

Fluxo Completo de Tensores no Vision Transformer Canônico

$P = 16$ | $N = (224/16)^2 = 196$ | $D = 768$

1

Imagem de Entrada



Pixels brutos 2D contínuos

$[B, 3, 224, 224]$

2

Patch Embedding

196 Patches
14×14 na grade
D = 768 canais

Conv2D(k=16, s=16) proj: 768px → D

$[B, 196, 768]$

3

[CLS] + Pos Embeddings

Token [CLS]
 $196 + 1 = 197$
+ E_pos aprendível

concat([CLS], tokens) + E_pos 1D

$[B, 197, 768]$

4

L × Encoder Blocks

12 Blocos Pre-LN
Residual + GELU
Dimensão Fixa

Pre-LN + MSA 12 heads + MLP 4×

$[B, 197, 768]$

5

MLP Head ([CLS])

Vetor [CLS]
LayerNorm(z_cls)
Linear(768, C)

Extrai $z_L[:, 0]$ e projeta classes

$[B, \text{num_classes}]$

Atenção Canônica: Em todos os blocos, a dimensão de representação permanece fixa em $[B, 197, 768]$ (arquitetura colunar isotrópica herdada do BERT).

Parâmetros: **86M (ViT-Base)**

FLOPs: **17.6 GFLOPs**

O Diagnóstico: As 3 Barreiras Críticas do ViT no Mundo Real

Por que a indústria e a pesquisa precisaram evoluir além da arquitetura original de Dosovitskiy et al.?

01

SEM VIÉS INDUTIVO



A Fome de Dados (Data Hunger)

ACURÁCIA IMAGENET-1K PURO

ViT 79.9% vs CNN 83.2%

Sem premissas rígidas de convolução (localidade 2D e equivariância à translação), o ViT requer 300M de imagens (JFT-300M) para convergir com generalização superior.

Exige Pré-Treino Bilionário**02**

TOKENS UNIFORMES



Rigidez de Escala (Isotrópica)

RESOLUÇÃO ESPACIAL FIXA

14×14 constante em L camadas

Modelos de detecção e segmentação (como FPN e Mask R-CNN) exigem pirâmides com features multiescala (stride 4, 8, 16, 32). O ViT canônico mantém resolução fixa.

Incompatível com Visão Densa**03**

GARGALO DE MEMÓRIA GPU



Custo Quadrático $O(N^2)$

MATRIZ $Q \cdot K^T$ EM 800×800PX**2.500 tokens → 6.25M pares**

Para capturar detalhes finos ou processar imagens de alta resolução, o custo de memória da autoatenção escala com $(H \cdot W)^2$, estourando a VRAM (CUDA Out of Memory).

CUDA Out of Memory

O Mapa Evolutivo: As Soluções de Engenharia para os Gargalos do ViT

A árvore genealógica dos modelos modernos e os papéis de cada inovação arquitetural



ViT Canônico (Dosovitskiy et al., 2020)

Patch Slicing (16×16) • Autoatenção Global $O(N^2)$ • Fome de Dados (JFT-300M)

Ponto de Partida da Aula 05 → 4 Soluções de Engenharia

DeiT (2021)

ImageNet-1k Puro

Touvron et al. (Meta / Sorbonne)

Eficiência de Dados & Destilação

- ✦ Destilação de CNN (RegNetY)
- ✦ Distillation Token dedicado
- ✦ Hard Distillation supera Soft

PVT (2021)

Deteção & FPN

Wang et al. (Nanjing / Oxford)

Visão Densa em Pirâmide

- ✦ 4 Estágios Hierárquicos (H/4 a H/32)
- ✦ Spatial-Reduction Attention (SRA)
- ✦ Features multiescala nativas

Swin Transformer (2021)

Complexidade $O(N)$

Liu et al. (MSRA / Marr Prize)

Atenção Linear em Janelas

- ✦ Janelas Locais $M \times M$ (W-MSA)
- ✦ Shifted Windows (SW-MSA)
- ✦ Cyclic Shift vetorizado

DINO (2021)

Emergência Semântica

Caron et al. (Meta AI)

Auto-Supervisão sem Rótulos

- ✦ Student-Teacher sem rótulos
- ✦ Centering + Sharpening anti-colapso
- ✦ Segmentação não-supervisionada

FRONTEIRAS MODERNAS

Extensões abordadas no fechamento da aula:

MAE: Reconstrução de 75% mascarado

ConvNeXt: A modernização das CNNs

DINOv2: Fundação visual em bilhão de parâmetros

DeiT: Data-Efficient Image Transformers via Destilação


Touvron et al. (Meta/Sorbonne, 2021): Como treinar ViT competitivo usando apenas o ImageNet-1k

ARQUITETURA
DEiT

Destilação Através da Atenção com o Distillation Token (Touvron et al., Meta/Sorbonne 2021)

Zero Dados Externos • 100%
ImageNet-1k

Top-1: 79.9% → 85.2%
(+5.3%)



MECÂNICA DE DESTILAÇÃO DO DEiT

1. Token de Classe [CLS] → Hard Target

Supervisionado diretamente pelo rótulo real (Ground Truth y).

$$L_{CE} = -\log(\text{Softmax}(z_{cls})[y])$$

2. Distillation Token [DST] → Teacher Target

Forçado a reproduzir a predição da CNN especialista.

Absorve o viés indutivo de localidade 2D!

3. Teacher CNN (RegNet / ResNet) 🔒

Totalmente congelado: zero gradientes na backprop.

Fornece alvos estáveis (Soft ou Hard) para o ViT.

4. Inferência em Produção (Sem a CNN!)

A CNN é descartada! A predição final combina as duas cabeças:

$$y_{final} = \frac{1}{2} (y_{cls} + y_{dist})$$

💡 O [DST] atua como um 'aluno ouvinte' dedicado à CNN.

O Dilema das Tarefas Densas: Detecção de Objetos e Segmentação Semântica

Por que a estrutura isotrópica do ViT original falha ao ser conectada a cabeças como FPN, RetinaNet e Mask R-CNN?

SITUAÇÃO-PROBLEMA

O Dilema da Visão Densa: Por que o ViT Canônico Falha em Detecção e Segmentação?

Falta de Pirâmide Espacial + Complexidade $O(N^2)$

✗ ViT Canônico: Arquitetura Isotrópica (Coluna Fixa)

Uma única resolução espacial ($H/16 \times W/16$) mantida fixa em todos os blocos.

Bloco L (14×14 , $D=768$)

...

Bloco 2 (14×14 , $D=768$)

Bloco 1 (14×14 , $D=768$)

O Gargalo Fatal: Objetos pequenos (ex: pedestres em 16×16 px) ocupam apenas 1 token e perdem contornos finos. Objetos gigantes cobrem dezenas de tokens sem agregação multiescala.

✓ O Padrão de Ouro: Pirâmide Hierárquica (FPN / CNN)

Redução progressiva da resolução espacial com enriquecimento de canais semânticos.

Estágio 4: $H/32 \times W/32$ ($C4$)

Estágio 3: $H/16 \times W/16$ ($C3$)

Estágio 2: $H/8 \times W/8$ ($C2$)

Estágio 1: $H/4 \times W/4$ ($C1$ - Alta Resolução)

O Desafio de Engenharia: No Estágio 1 ($H/4 \times W/4$), uma imagem de 800×800 gera **40.000 tokens**. Como calcular autoatenção sem estourar a GPU?

A resposta veio com dois marcos da literatura em 2021: **PVT** (Spatial-Reduction Attention) e **Swin Transformer** (Janelas Locais $O(N)$).

Próximo passo: PVT →

Pyramid Vision Transformer (PVT) e Spatial-Reduction Attention (SRA)


Wang et al. (2021): Transformando o ViT em um backbone hierárquico com redução espacial de chaves e valores

FIGURE 16-5 Pyramid Vision Transformer (PVT) for Dense Prediction Tasks

Wang et al. (ICCV 2021)

4 Estágios Hierárquicos

Compatível com FPN



Lab 1: Simulador de Pirâmide Visual e Spatial-Reduction Attention

Ajuste a resolução da imagem (H×W) e a taxa de redução R_i e veja o consumo de VRAM e FLOPS em cada estágio

LAB INTERATIVO

Simulador de Pirâmide Visual: Viabilidade de Resoluções Altas com SRA vs MSA Canônico

224×224

448×448

800×800 (COCO)

1024×1024 (Médica)

Configuração de Atenção

ALGORITMO DE AUTOATENÇÃO:

SRA (PVT Reduzido)

MSA Canônico

Fator de Redução R_1 no Estágio 1:

R=1

R=2

R=4

R=8

Reduz chaves e valores K, V por um fator de $R_1^2 = 64\times$

MEMÓRIA VRAM MATRIZ DE ATENÇÃO (BATCH=2, H=8):

2.0 GB

✓ GPU Operando com Segurança

Decomposição por Estágio na Resolução 800×800

Estágio 1 (H/4)

Res: 200×200

Tokens Q:

40.000

Tokens K, V (R=8):

625

Matriz Q·KT:

25.00M pares

Estágio 2 (H/8)

Res: 100×100

Tokens Q:

10.000

Tokens K, V (R=4):

625

Matriz Q·KT:

6.25M pares

Estágio 3 (H/16)

Res: 50×50

Tokens Q:

2.500

Tokens K, V (R=2):

625

Matriz Q·KT:

1.56M pares

Estágio 4 (H/32)

Res: 25×25

Tokens Q:

625

Tokens K, V (R=1):

625

Matriz Q·KT:

0.39M pares

💡 **SRA em Ação:** Com R=8, o número de chaves no Estágio 1 cai de 40.000 para apenas **625**, tornando viável treinar detectores Mask R-CNN com backbones Transformers!

The Swin Transformer: Atenção em Janelas Locais (W-MSA)

Liu et al. (ICCV 2021, Marr Prize): Da complexidade quadrática $O(N^2)$ à complexidade linear $O(N)$

SWIN TRANSFORMER

Window Multi-Head Self-Attention (W-MSA): Complexidade Linear $O(N)$

Liu et al. • ICCV 2021 Best Paper (Marr Prize)

1. Autoatenção Global (ViT Canônico)

$O(N^2)$

Cada patch calcula atenção com TODOS os outros

$$\Omega(\text{MSA}) = 4 \cdot (h \cdot w) \cdot C^2 + 2 \cdot (h \cdot w)^2 \cdot C$$

Para 3.136 patches em 224×224 (stride 4), o termo quadrático requer **19.6 milhões de operações** por canal!

2. Window Self-Attention (W-MSA no Swin)

$O(N)$ LINEAR

Janela 1
($M \times M$)

Janela 2
($M \times M$)

Janela 3
($M \times M$)

Janela 4
($M \times M$)

$$\Omega(\text{W-MSA}) = 4 \cdot (h \cdot w) \cdot C^2 + 2 \cdot M^2 \cdot (h \cdot w) \cdot C$$

Com janela fixa $M=7$ (49 patches), o termo de atenção escala estritamente **linear em relação à área** ($h \cdot w$)!

Ganho de Eficiência: Para $hw = 56 \times 56 = 3.136$ patches e $M = 7$: W-MSA consome apenas **0.3M ops** contra **19.6M ops** da atenção global (economia de **64x**!).

Viável para 4K e 8K

Shifted Windows (SW-MSA): Interligando Janelas sem Custo Global

Deslocando a grade de janelas por $(\lfloor M/2 \rfloor, \lfloor M/2 \rfloor)$ para capturar relações entre bordas


SHIFTED WINDOWS

SW-MSA: Construindo Conexões Cruzadas entre Janelas Vizinhas

Deslocamento: $(\lfloor M/2 \rfloor, \lfloor M/2 \rfloor) = (3, 3)$ patches

Camada ℓ : W-MSA (Partição Regular)

Grade estática com 4 janelas 2×2 isoladas




⚠ Limitação: Patches de janelas distintas não se comunicam



SHIFT
(+3, +3)

Camada $\ell+1$: SW-MSA (Janelas Deslocadas)

Grade transladada conecta bordas e centros



✓ A janela central engloba pixels das 4 janelas da camada ℓ !

Novo Gargalo de Engenharia: Ao deslocar a grade, surgiram **9 sub-janelas de tamanhos diferentes**. Fazer padding aumentaria computação; janelas separadas quebrariam a GPU.

Solução: Cyclic Shift
→


Cyclic Shift & Masked Attention: O Golpe de Mestre da Implementação

Como processar janelas deslocadas de tamanhos irregulares em um batch uniforme sem padding

MECÂNICA ELEGANTE Cyclic Shift & Masked Attention: Vetorização Pura em GPU


Zero Padding • 4 Janelas Regulares $M \times M$

1. Partição com Shift




Blocos A, B e C ficam isolados nas bordas superiores e esquerdas.

2. Cyclic Shift (Rolagem)




A e C são rolados para a direita e base. Grade volta a ser 2×2 perfeita!

3. Masked Attention



Soma **-100** aos pares não vizinhos. Softmax zera a atenção espúria!

4. Reverse Cyclic Shift



Rola os tensores de volta para as coordenadas espaciais originais da imagem.

Fórmula com Máscara: $\text{Attention} = \text{Softmax} \left(\frac{Q \cdot K^T}{\sqrt{d}} + \text{Mask} \right) \cdot V$. Graças a isso, o número de janelas é mantido exatamente em $\lceil H/M \rceil \times \lceil W/M \rceil$ com processamento 100% paralelo na GPU.

Eficiência Máxima em Silício

DINO: Self-Supervised Vision Transformers sem Rótulos

Caron et al. (Meta AI, ICCV 2021): Aprendendo representações visuais puras por auto-destilação sem pares negativos

DINO (ICCV 2021) Self-distillation with NO labels: Treinamento Auto-Supervisionado em ViT

Zero anotação manual • Sem pares negativos

Estratégia Multi-Crop

A partir de 1 imagem sem rótulo, sintetizamos visões complementares:

2× Global Views (224×224)

Cobrem > 50% da área da imagem. Enviadas para Teacher e Student.

Várias Local Views (96×96)

Cobrem partes pequenas (< 50%). Enviadas apenas para o Student!

💡 *O aluno deve reconstruir o todo a partir das partes!*

Student ViT (θ_s)

Gradientes

Processa todas as visões (globais e locais). Atualizado diretamente por Backprop.

$$P_s(x) = \text{Softmax}(g_s(x) / \tau_s)$$

Teacher ViT (θ_t)

EMA (Congelado)

Processa apenas visões globais. Pesos atualizados via Momentum:

$$\theta_t \leftarrow \lambda \theta_t + (1 - \lambda) \theta_s$$

FUNÇÃO DE PERDA DE AUTO-DESTILAÇÃO:

$$\min_{\theta_s} \sum_{\{x_g \in V_g\}} \sum_{\{x_i \in V\}} - P_t(x_g) \cdot \log(P_s(x_i))$$

Cross-Entropy Pura

A Grande Barreira: No aprendizado auto-supervisionado sem negativos, existe o risco mortal de **colapso de representação** (o modelo prevê a mesma saída constante para qualquer imagem).

Como o DINO evita o colapso? →

A Mecânica do DINO: Prevenção de Colapso e a Propriedade Emergente

Momentum Encoder (EMA), Centering, Sharpening e a descoberta de máscaras de segmentação sem supervisão

Prevenção de Colapso de Representação

Centering + Sharpening

1. Centering (Subtração da Média Móvel)

$$g_t(x) \leftarrow g_t(x) - c$$

O vetor de centro c acumula a média móvel dos logits do professor. Impede que **uma dimensão domine** e cause colapso determinístico.

↳ Efeito colateral se usado sozinho: Força distribuição para uniforme plana!

2. Sharpening (Agudização Térmica)

$$\tau_t < \tau_s \text{ (0.04 vs 0.1)}$$

Ao dividir os logits do professor por uma temperatura muito baixa ($\tau_t = 0.04$), o Softmax cria picos acentuados de certeza. Impede o **colapso uniforme**!

⚖️ O equilíbrio das duas forças opostas garante convergência auto-supervisionada estável!

A Propriedade Emergente Revolucionária

Segmentação sem Supervisão



RGB Original



ViT Supervisionado



DINO (Emergente)

Ao inspecionar a autoatenção da última camada do token **[CLS]**, o DINO produz automaticamente **máscaras de segmentação com bordas nítidas** do objeto em primeiro plano.

☀️ Cada cabeça de atenção especializa-se em partes anatômicas distintas sem jamais ter recebido supervisão de partes de objetos!



Lab 2: Visualizador de Mapas de Atenção: DINO vs ViT Supervisionado

Explore visualmente como a atenção auto-supervisionada isola contornos semânticos limpos em comparação com a supervisão tradicional

LAB INTERATIVO

Visualizador de Atenção Emergente: DINO Auto-Supervisionado vs ViT Supervisionado

 Águia Real em Voo Carro Esportivo Vintage Cão Golden Retriever

★ DINO Auto-Supervisionado

ViT Supervisionado (Padrão)



DINO Cabeça #1: Cabeça & Olho

✓ **Segmentação Emergente:** O DINO ignora completamente o ruído de fundo (grama, céu, asfalto) e foca estritamente no objeto.

Especialização das 6 Cabeças de Atenção (Multi-Head)

Token [CLS] • Camada 12

Head #1
Cabeça & Olho 18%**Head #2**
Asa Esquerda 34%**Head #3**
Asa Direita 36%**Head #4**
Cauda & Garras 22%**Head #5**
Silhueta Total 88%**Head #6**
Contorno de Borda 15%

FOCO SEMÂNTICO DA CABEÇA #1 (Cabeça & Olho):

Bico afiado e pupila da ave.

Área de saliência normalizada coberta pelo mapa de atenção: **18%**.

☀ **Nenhuma dessas regiões foi anotada por humanos. A segmentação semântica é uma propriedade emergente pura da auto-destilação com momentum!**

MAE & DINOv2: As Fronteiras Modernas do Pré-Treinamento Visual

Reconstrução pixel-level com 75% de máscara (He et al.) e representações universais em escala de bilhão (DINOv2)

MAE: Masked Autoencoders (He et al., 2022)

75% Mascarado

FLUXO ASSIMÉTRICO:

Velocidade 3x a 4x

1. Imagem fatiada em patches; **75% são descartados aleatoriamente.**
2. **Encoder ViT Pesado** processa apenas os **25% de patches visíveis.**
3. **Decoder Leve** recebe patches + tokens [MASK] e reconstrói pixels brutos (MSE Loss).

Por que 75%? Imagens possuem alta redundância espacial. O modelo só aprende semântica profunda ao ser forçado a reconstruir o objeto a partir de pistas escassas.

🎯 ViT-Huge com MAE atinge **87.8% Top-1** no ImageNet-1k com treino escalável e estável.

DINOv2: Modelos Visuais Universais (2023)

1B Parâmetros (ViT-G)

PILARES DO MODELO DE FUNDAÇÃO:

- **Dataset LVD-142M:** 142 milhões de imagens limpas e deduplicadas automaticamente.
- **Treino Híbrido:** DINO (nível de imagem) + iBOT (nível de patch mascarado) + SwiGLU FFN.
- **FlashAttention & Nested Tensors:** Otimização de hardware no silício para treinar ViT-Giant.

O PODER DAS CARACTERÍSTICAS CONGELADAS (FROZEN FEATURES):

Um simples classificador linear congelado sobre o DINOv2 supera o fine-tuning supervisionado de outros backbones em classificação, profundidade monocular e segmentação!

🚀 É o modelo padrão atual para extração de embeddings visuais em sistemas modernos de RAG e busca multimodal.

ConvNeXt: A Modernização da Convolução nos Anos 2020

Liu et al. (CVPR 2022): Como atualizar uma ResNet-50 aplicando as lições de design do Swin Transformer

CONVNEXT (CVPR 2022)

A ConvNet for the 2020s: Modernizando a ResNet com as Lições do Swin

Liu et al. (Meta AI) • 78.8% → 82.1% Top-1

1. Macro Design

78.8% → 79.4%

Stem estilo "Patchify" (Conv 4×4 stride 4) •
Estágios 1:1:3:1 (como Swin)

Etapa 1 de 4

2. ResNeXt & Kernel 7×7

79.4% → 80.6%

Depthwise Convolutions separáveis • Kernel 7×7
para campo receptivo amplo

Etapa 2 de 4

3. Inverted Bottleneck

80.6% → 81.0%

Inverte expansão: 1× → 4× → 1× (idêntico à MLP
do Transformer)

Etapa 3 de 4

4. Micro Design & LN

81.0% → 82.1%

Substitui ReLU por GELU • Apenas 1 ativação e 1
LayerNorm por bloco (Sem BatchNorm)

Etapa 4 de 4



Acurácia Idêntica ou Superior ao Swin

ConvNeXt-T (82.1%) bate Swin-T (81.3%) usando exatamente os mesmos FLOPs (4.5G) e parâmetros (28M).



Vantagens Práticas em Produção

Sem necessidade de shifting de janelas, sem máscaras de atenção complexas e compatibilidade nativa com TensorRT e dispositivos edge (NPU/CoreML).

Lab 3: Quiz de Fixação & Matriz de Decisão Arquitetural

Teste seus conhecimentos sobre DeiT, PVT, Swin, DINO e consulte o guia de seleção de modelos para projetos reais

LAB FINAL Avaliação de Fixação & Guia de Seleção Arquitetural na Indústria

Quiz de Fixação (0/4)

Matriz de Decisão Industrial

QUESTÃO 1 DE 4

Acertos até agora: 0

1. No DeiT (Data-Efficient Image Transformer), por que a destilação "Hard" (usando o argmax do professor CNN) superou a destilação "Soft" clássica baseada em divergência KL com temperatura?

A) Porque a destilação Hard elimina a necessidade de calcular gradientes no modelo Student.

B) Porque o argmax do professor atua como um pseudorótulo categórico rígido, sem hiperparâmetro de temperatura sensível e com gradientes mais assertivos em conjunto com augmentations agressivas (CutMix/Mixup).

C) Porque a destilação Soft é matematicamente incompatível com a arquitetura Multi-Head Attention.

D) Porque a destilação Hard utiliza apenas o token [CLS], descartando o [DIST].