

CLIP: Contrastive Language-Image Pre-training

A Revolução Multimodal da OpenAI: Aprendizado Não Supervisionado, Zero-Shot Transfer, Espaços Latentes e Detecção de Anomalias

Etapa / Aula 06

Faculdade Infnet • Pós-Graduação em Visão Computacional com CNNs e Transformers

✦ Aprendizado Não Supervisionado

✦ Alinhamento Multimodal

✦ Zero-Shot Learning

✦ Espaço Latente Multimodal

✦ Open-Vocabulary Vision

✦ Detecção de Anomalias


O Gargalo da Visão Supervisionada Tradicional: O Dilema do Vocabulário Fechado

Por que classificadores treinados em 1.000 classes one-hot (ImageNet) limitaram a indústria por uma década?

Visão Supervisionada de Vocabulário Fechado

ImageNet 1k • Softmax de Dimensão Fixa ($C = 1.000$)

Gargalo Crítico



Rotulagem Cara
Anotação manual finita


Semântica Nula
Índices numéricos isolados

Rigidez Zero-Shot
Incapaz de prever classe nova

Visão Multimodal de Vocabulário Aberto (Open-Vocabulary)

CLIP • Aprendizado Contrastivo com Linguagem Natural

Solução Universal



Supervisão Web
400M pares da internet

Semântica Rica
Frases e conceitos abertos

Zero-Shot Nativo
Qualquer categoria em texto

A Solução CLIP: Contrastive Language-Image Pre-training


Radford et al. (OpenAI, 2021): Conectando Visão e Linguagem Natural em Escala de Internet (400M Pares)

Radford et al. (OpenAI, 2021)

Dataset WIT: 400 Milhões de pares (Imagem, Texto) raspados da Web

Two-Tower Network

L2 Hypersphere D=512



1. Duas Torres Assíncronas

Vision e Text processam batch separadamente

2. Projeção Linear & Norm L2

Ambos vetores caem na hipersfera unitária D=512

3. Matriz $N \times N$ de Similaridade

Produto escalar de todos os pares escalado por τ

4. Otimização InfoNCE

Maximiza diagonal verde e minimiza pares falsos

A Matriz de Similaridade e a Perda Contrastiva Simétrica

Maximizando a diagonal de pares corretos e repelindo os pares negativos com temperatura aprendível τ

Matriz de Logits Multimodal: $S_{i,j} = \frac{\hat{I}_i \cdot \hat{T}_j}{\tau}$

Diagonal Positiva

	Textos →	$\hat{T}_1$ (cão)	$\hat{T}_2$ (carro)	$\hat{T}_3$ (avião)	$\hat{T}_4$ (gato)
Imagens ↓					
$\hat{I}_1$ (cão)		+24.5 Par Correto	-1.2	-3.4	+4.1
$\hat{I}_2$ (carro)		-2.8	+28.2 Par Correto	+3.2	-5.1
$\hat{I}_3$ (avião)		-4.5	+2.1	+26.9 Par Correto	-3.8
$\hat{I}_4$ (gato)		+3.9	-4.2	-2.1	+25.4 Par Correto

1. Perda Imagem → Texto (Por Linhas)

Softmax ao longo das colunas

$$\mathcal{L}_{\text{img}} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(S_{i,i})}{\sum_{j=1}^B \exp(S_{i,j})}$$

2. Perda Texto → Imagem (Por Colunas)

Softmax ao longo das linhas

$$\mathcal{L}_{\text{txt}} = -\frac{1}{B} \sum_{j=1}^B \log \frac{\exp(S_{j,j})}{\sum_{i=1}^B \exp(S_{i,j})}$$

3. Perda CLIP Simétrica Total

Média Aritmética

$$\mathcal{L}_{\text{CLIP}} = \frac{1}{2} (\mathcal{L}_{\text{img}} + \mathcal{L}_{\text{txt}})$$

🔥 Temperatura Aprendível: $\tau = \exp(\log \tau)$

Evita hiperparâmetro manual; o próprio gradiente ajusta a escala dinâmica dos logits para afinar a nitidez das probabilidades Softmax. No PyTorch: `logit_scale = nn.Parameter(torch.ones(1) * np.log(1 / 0.07))`.

Laboratório Interativo: Simulador da Perda Contrastiva do CLIP

Interaja com a matriz de logits, altere a temperatura τ e analise a entropia do Softmax e da Loss


Cenário: **✓ Convergido (Alinhado)**

⚡ Início do Treino (Ruído)

⚠ Confusão Semântica



Temperatura τ :



0.07



Logits $S = C/\tau$

Softmax (Img→Txt)

Softmax (Txt→Img)

Matriz de Logits: $S = \text{Cosseno} / 0.07$

Batch B = 4 pares

	$\hat{\tau}_1$ Cão (Golden)	$\hat{\tau}_2$ Carro Esportivo	$\hat{\tau}_3$ Avião Comercial	$\hat{\tau}_4$ Pizza de Forno
$\hat{I}_1$ Cão (Golden)	12.1 PAR CORRETO	0.7	-0.3	0.6
$\hat{I}_2$ Carro Esportivo	1.1	13.1 PAR CORRETO	2.1	-0.7
$\hat{I}_3$ Avião Comercial	-0.1	1.7	12.6 PAR CORRETO	0.3
$\hat{I}_4$ Pizza de Forno	0.4	-0.9	0.1	13.4 PAR CORRETO

Valores da Perda InfoNCE

Excelente

Perda Imagem → Texto (L_{img}):

0.0000

Perda Texto → Imagem (L_{txt}):

0.0000

PERDA TOTAL SIMÉTRICA $L_{\text{CLIP}} = 0.5 \times (L_{\text{img}} + L_{\text{txt}})$

0.0000

Teórico Mínimo: 0.0000 • Teórico Máximo: $-\log(1/4) = 1.3863$

Efeito da Temperatura: Se τ for muito pequeno (< 0.03), o Softmax vira uma função degrau rígida (gradientes saturam). Se τ for alto (> 0.3), a distribuição se espalha uniformemente e o modelo perde a capacidade de discriminar nuances finas.

Aplicações do Aprendizado Não Supervisionado Multimodal

Como o CLIP desbloqueou uma nova geração de sistemas visuais sem anotação humana direta

[Pilar 1 ↗](#)

Busca Semântica Cross-Modal

Text-to-Image & Image-to-Text Retrieval

Pesquise em bancos de bilhões de imagens utilizando linguagem natural livre ("cachorro usando óculos escuros na praia"), sem necessidade de tags pré-annotadas.

ENGENHARIA: Vetores normalizados + Indexação rápida Faiss / Qdrant

[Pilar 2 ↗](#)

Guia Semântico para IA Generativa

DALL-E 2, Stable Diffusion, VQGAN+CLIP

O CLIP atua como juiz multimodal: sua perda contrastiva guia a otimização de latentes nos modelos de difusão e autorregressivos para manter fidelidade ao texto.

ENGENHARIA: Gradientes de similaridade de cosseno $d(\cos)/dz$

[Pilar 3 ↗](#)

Curadoria de Datasets Massivos

Filtragem de Ruído em Bilhões de Amostras

Construção automática do LAION-400M e LAION-5B: remoção de pares de internet onde o texto não corresponde ao conteúdo visual por threshold de cosseno.

ENGENHARIA: Filtro automático: descartar se $\cos(I, T) < 0.28$

[Pilar 4 ↗](#)

Moderação de Conteúdo e Segurança

Deteção de Violações Multimodais Sem Rótulos

Identificação de conteúdo nocivo, discurso de ódio camuflado em memes e violações de diretrizes sem retrainar classificadores para cada nova ameaça.

ENGENHARIA: Prompts sentinelas: "a photo depicting violent behavior"

PARADIGMA


O aprendizado auto-supervisionado multimodal substitui o custo da anotação humana manual pela redundância semântica natural da linguagem presente na web.

Sem classes fixas • Sem overfit de domínio

Representações Gerais e a Geometria da Hiperesfera Multimodal

Como conceitos visuais e linguísticos convergem para as mesmas regiões do espaço métrico unitário S^{D-1}

Geometria da Hiperesfera Unitária S^{D-1} ($D = 512$)



Espaço Compartilhado

1. Isomorfismo Semântico Cross-Modal

Imagens e textos que compartilham significado convergem para a mesma vizinhança topológica na hiperesfera, independentemente da modalidade de origem.

2. Separação de Conceitos Não Relacionados

Conceitos semânticos ortogonais (ex: "avião a jato" vs "golden retriever") apresentam produto escalar próximo de zero na dimensão $D=512$, garantindo alta discriminação.

3. Aritmética Vetorial Multimodal

Assim como no Word2Vec, é possível somar e subtrair vetores:

$$\text{Emb}(\text{Imagem Homem}) + \text{Emb}(\text{"óculos"}) \approx \text{Emb}(\text{Imagem Homem com Óculos})$$

Robustez Fora da Distribuição (OOD): Quebrando o Overfitting de Datasets

CLIP Zero-Shot vs ResNet/ViT Supervisionados em ImageNet-V2, ImageNet-R, ImageNet-A e Sketch

BENCHMARK OFICIAL OPENAI

Comparação empírica de acurácia Top-1: ResNet-50 Supervisionada vs CLIP ViT-L/14 Zero-Shot

■ ResNet-50 (Supervisionada ImageNet)

■ CLIP ViT-L/14 (Zero-Shot)

ImageNet Padrão

Validação IID (Mesma Distribuição)



Δ CLIP: 0%

ImageNet-V2

Nova coleta com mesmo protocolo



Δ CLIP: -6.1 pp

ImageNet-R (Renditions)

Cartuns, arte, brinquedos, esculturas



Δ CLIP: +1.5 pp

ImageNet-Sketch

Esboços em preto e branco



Δ CLIP: -27.9 pp

ImageNet-A (Adversarial)

Imagens naturais que enganam CNNs



Δ CLIP: +0.9 pp


💡 Por que a ResNet supervisionada entra em colapso no ImageNet-A (2.7%) enquanto o CLIP mantém 77.1%? Modelos supervisionados sofrem de *shortcut learning* (overfitting em texturas espúrias de fundo). O CLIP aprendeu semântica conceitual robusta com 400M de descrições humanas variadas.

Zero-Shot Classification: Inferência Direta sem Treinar Novos Pesos

Transformando a classificação de C classes arbitrárias em um problema de alinhamento com a imagem

INFERÊNCIA ZERO-SHOT Como classificar qualquer conjunto de C classes sem nenhum dado de treino

$W_{\text{class}} = \text{Normalize}(\text{TextEncoder}(\text{Prompts})) \in \mathbb{R}^{(C \times D)}$



⚡ **Custo de Inferência Zero-Shot:** As representações textuais $\hat{T}_c$ das C classes são pré-computadas e cacheadas apenas UMA vez! Para cada nova imagem, executa-se apenas a torre visual e um produto vetorial ultra-rápido.

Engenharia de Prompts e Ensembling de Prompts no CLIP

Por que palavras isoladas sofrem com polissemia e como templates enriquecem a representação em até +5%

Nível 1 (Baseline Fraco)

Baseline

Palavra Isolada (Single Label)

Passar apenas o rótulo puro como texto para o Text Encoder.

```
prompt = "crane"
```

⚠ Risco Crítico: Polissemia

"crane" pode significar a ave pernalta (pássaro) ou o guindaste de construção civil! O embedding textual fica ambíguo no espaço latente.

ImageNet Top-1:

67.5%

Nível 2 (Prompt Engineering)

+1.3%

Template com Contexto Visual

Enquadrar a classe em uma estrutura de legenda fotográfica típica da web.

```
prompt = "a photo of a {c}."
// ou: "a photo of a {c}, a type of bird."
```

✓ Insight de Engenharia

Como o CLIP foi treinado em 400M de legendas reais, sentenças completas coincidem com a distribuição de texto pré-treinada do WIT.

ImageNet Top-1:

68.8% (+1.3%)

Nível 3 (Estado da Arte)

+5.0%

Prompt Ensembling (80 Templates)

Média dos embeddings normalizados de 80 variações de contexto estilístico.

```
"a centered photo of a {c}."
"a cropped photo of the {c}."
"a photo of many {c}s."
"a close-up photo of a {c}."
T_bar = Normalize(Sum(T_k))
```

🚀 Ganho Maciço de Generalização

Cancela a variância de termos idiomáticos e estabiliza a direção latente na hiperesfera sem nenhum custo computacional na inferência da imagem!

ImageNet Top-1:

72.5% (+5.0%)

💡 **Equivalente de Engenharia:** No paper seminal, Radford et al. provaram que o ganho de +5.0% com Prompt Ensembling equivale a treinar o modelo com 4 vezes mais dados rotulados, a um custo computacional adicional ZERO no pipeline de produção!

Laboratório Interativo: Zero-Shot Classification & Prompt Tuning

Experimente diferentes imagens de teste, edite templates de prompts e observe as probabilidades em tempo real

Imagem Teste: **Guindaste de Obras** Grou (Pássaro Crane) Siberian Husky na Neve Carro Esportivo Vermelho

Modo Prompt: 1. Single Word **2. Template ("a photo of...")** 3. Desambiguação Rica 4. Customizado

AMOSTRA SELECIONADA

Construção



Guindaste de Obras

Guindaste mecânico telescópico em canteiro de obras.

[1, 3, 224, 224]

Diagnóstico de Ambiguidade: Se usarmos apenas a palavra solta "crane", o modelo hesita entre a máquina e a ave. Ao adicionar contexto rico, o CLIP desambigua o conceito com mais de 90% de confiança!

Distribuição de Confiança Softmax (Top-5 Classes)

Predição: "crane" (99.3%)

✓ 1. "a photo of a crane"	cos: 0.78	99.3%
2. "a photo of a car"	cos: 0.42	0.6%
3. "a photo of a plane"	cos: 0.25	0.1%
4. "a photo of a bird"	cos: 0.10	0.0%
5. "a photo of a dog"	cos: 0.07	0.0%

⚡ **Engenharia de Prompt em Produção:** Observe como trocar de "Single Word" para "Desambiguação Rica" expande a margem de segurança da probabilidade líder de ~50% para mais de 90%, blindando o sistema contra erros industriais.

Pesos Pré-Treinados para Tarefas Downstream: Do Linear Probe ao CoOp

Três estratégias para adaptar as representações universais do CLIP ao ambiente industrial

Estratégia 1

Zero Esquecimento

Linear Probe

Congela 100% dos encoders do CLIP e treina exclusivamente uma camada linear (regressão logística / Ridge) sobre os embeddings $\hat{I}$.

ESTADO DOS PESOS:

Vision Backbone: CONGELADO ❄️
Head: TREINÁVEL 🔥 (W_{new})

✓ Vantagem de Produção:

Treina em segundos na CPU via Scikit-Learn ou PyTorch; preserva 100% da robustez OOD original.

Custo Treino: Muito Baixo

Estratégia 2

Alto Risco OOD

Full Fine-Tuning

Descongela todos os parâmetros do Vision Encoder com taxa de aprendizado ultra-baixa (ex: $1e-5$) para ajustar os pesos ao dataset específico.

ESTADO DOS PESOS:

Vision Backbone: TREINÁVEL 🔥
Head: TREINÁVEL 🔥

⚠️ O Perigo do Catastrophic Forgetting:

Ganha 1% no dataset alvo, mas destrói a robustez fora do domínio (OOD) e aniquila a capacidade zero-shot.

Custo Treino: Muito Alto

Estratégia 3 (Moderna)

CoOp / PEFT

Context Optimization (CoOp)

Zhou et al. (2022): Substitui palavras manuais do prompt por vetores contínuos aprendíveis $[V_1] [V_2] \dots [V_M] [CLASS]$ mantendo os dois backbones 100% congelados!

ESTADO DOS PESOS:

Backbones: CONGELADOS ❄️ (Zero GPU)
Prompt Tokens: APRENDÍVEIS ✨

🚀 Equilíbrio Perfeito:

Aprende com 1 a 16 exemplos (few-shot) superando engenharia manual e preservando a generalização multimodal.

Custo Treino: Mínimo (PEFT)

💡 **Recomendação Prática:** Para aplicações empresariais com datasets especializados (ex: imagens de satélite, patologia médica), inicie SEMPRE com Linear Probe ou CoOp antes de arriscar Fine-Tuning completo.


Visão de Vocabulário Aberto: Detecção e Segmentação Sem Rótulos Fixos

Como o OWL-ViT e o CLIPSeg usam representações multimodais para localizar qualquer conceito em texto livre

OWL-ViT (Google) / GLIP

Open-Vocabulary Detection

Substitui a cabeça de 80 classes fixas (COCO) de detectores por similaridade entre **tokens de patches espaciais do ViT** e o **prompt de texto livre**.



CLIPSeg / MaskCLIP

Open-Vocabulary Segmentation

Produce máscaras densas de segmentação pixel a pixel condicionadas por qualquer prompt de linguagem ou imagem de exemplo.



🚀 **O Salto Tecnológico:** OWL-ViT e CLIPSeg aposentaram a necessidade de treinar um modelo para cada objeto novo. Se você consegue descrever a entidade em linguagem natural, o sistema é capaz de localizá-la e segmentá-la imediatamente.

Detecção de Anomalias com CLIP: Paradigma Zero-Shot e OOD Industrial

Identificação de falhas e defeitos em manufatura (MVTec AD) sem dados defeituosos no treino



Abordagem 1: Prompts Opostos de Integridade

Text-Driven Zero-Shot

Define-se pares textuais antagônicos de normalidade versus modos de falha conhecidos da peça industrial:

$T_{normal} = \text{"a photo of a flawless, pristine transistor"}$ ✓

$T_{anomaly} = \text{"a photo of a cracked, damaged, burned transistor"}$ ⚠

Cálculo do Score de Anomalia Relativo:

$$S_{anomaly} = \frac{\exp(I \cdot T_{anom} / \tau)}{\exp(I \cdot T_{norm} / \tau) + \exp(I \cdot T_{anom} / \tau)}$$

Se $S_{anomaly} > \text{Limiar } \theta$ (ex: 0.5), classifica como DEFEITO.



Abordagem 2: Densidade e Distância Latente

Few-Shot Normal Memory

Coleta-se 10 a 50 imagens de peças perfeitamente sadias, extraí-se os embeddings visuais congelados do CLIP e calcula-se o centroide normal μ_{norm} .



✓ Não requer nenhuma amostra defeituosa no treinamento (Unsupervised Anomaly Detection).

 **Aplicações na Manufatura (MVTec AD):** O CLIP permite inspecionar peças de silício, garrafas de remédio, parafusos e tecidos sem precisar treinar redes complexas do zero, reduzindo o setup de inspeção de semanas para minutos.

Laboratório Interativo: Detecção de Anomalias Industriais Zero-Shot

Inspecione componentes industriais, ajuste o threshold de decisão e compare a detecção baseada em texto

🏭 Linha de Produção (MVTec AD): 🖨 Microchip PCB (Normal) 💥 Microchip PCB (Defeito) 🔩 Parafuso Industrial (Normal) ⚠ Parafuso Industrial (Defeito) 🧴 Frasco Farmacêutico (Defeito)

🎚 Threshold Limiar θ : 50%

ITEM INSPECIONADO PELA CÂMERA

Ground Truth: Defeito (Trilha Queimada)

CAM-01 • RGB 224x224



Microchip PCB

Trilha de cobre com curto-circuito e queimadura de solda visível.

T_norm: "a photo of a flawless pristine microchip pcb" (cos: 0.21)

T_anom: "a photo of a damaged defective microchip pcb" (cos: 0.82)

Zero-Shot Industrial: Não foi necessário treinar nenhuma rede com defeitos previamente.

Veredito do CLIP em Tempo Real

✓ Decisão Correta

🚨 ALARME: DEFEITO ENCONTRADO

Score: 100.0%

Limiar de Decisão: 50% • Diferencial: 50.0 pp

Normalidade (0%)

Anomalia (100%)

⚙ **Engenharia de Threshold:** Ajustar o threshold para baixo (ex: 35%) aumenta o recall (não deixa passar defeitos para o cliente final, mas gera mais falsos alarmes). Ajustar para cima (ex: 70%) é ideal para triagens de alta vazão.

Quiz Interativo: Arquitetura e Engenharia do CLIP

5 questões desafiadoras de pós-graduação sobre perda InfoNCE, Zero-Shot, downstream e anomalias

❓ Questão 1 de 5

Pontuação: 0 / 0

🔄 Reiniciar

1. No modelo CLIP (Radford et al., 2021), por que a normalização L2 obrigatória dos vetores de saída dos encoders visual e textual ($||\hat{\mathbf{v}}|| = 1$ e $||\hat{\mathbf{t}}|| = 1$) é indispensável antes do cálculo da matriz de logits?

A) Porque a normalização L2 reduz a dimensão dos tensores de 768 para 512.

B) Porque converte o produto escalar diretamente em Similaridade de Cosseno no intervalo $[-1, +1]$, impedindo que a magnitude espúria dos vetores domine a perda e estabilizando a dinâmica da temperatura τ .

C) Porque transforma a matriz de similaridade em uma matriz estritamente ortogonal.

D) Porque o PyTorch não possui implementação de Cross-Entropy para tensores desnormalizados.

Do Conceito ao Código: O Roteiro Prático do Notebook

Explorando a biblioteca oficial clip e Hugging Face Transformers em PyTorch no Google Colab

PRÁTICA EM CÓDIGO Pipeline completo do Jupyter Notebook (Google Colab 1-Click via PyTorch & Transformers)

Biblioteca Oficial CLIP + Hugging Face

Bloco 1

#1

Ambiente & Carga

Carregamento do modelo ViT-B/32 oficial e Hugging Face CLIPModel.

```
uv pip install ftfy regex tqdm git
+https://github.com/openai/CLIP.git
```

Bloco 2

#2

Tensores & Normalização

Inspeção passo a passo de tensores [B, 512] e cálculo manual de similaridade.

```
image_features /= image_features.norm(dim=-1, keepdim=True)
```

Bloco 3

#3

Zero-Shot no CIFAR-100

Avaliação de acurácia com prompts customizados vs single word.

```
logits = (100.0 * image_features @ text_features.T).softmax(dim=-1)
```

Bloco 4

#4

Busca Semântica Multimodal

Engine de busca Text-to-Image com galeria de fotos e ranking visual.

```
scores, indices = torch.topk(image_features @ query_feat.T, k=5)
```

Bloco 5

#5

Deteção de Anomalias

Inspeção de peças industriais (MVTec AD) com threshold configurável.

```
anomaly_score = P("damaged") / (P("pristine") + P("damaged"))
```

✓ No laboratório de código, você colocará a mão na massa com GPU T4/A100 no Colab, executando cada uma das equações vistas hoje em PyTorch puro.

Pronto para o Notebook! →