

GANs: Da DCGAN à Tradução com CycleGAN

Arquiteturas Estruturais, Síntese Condicional e Tradução Biomédica em Visão Computacional

Etapa / Aula 07

Faculdade Infnet • Pós-Graduação em Visão Computacional com CNNs e Transformers

✦ Modelagem Generativa Macro

✦ DCGAN & Tensores PyTorch

✦ Heurística Não-Saturante

✦ GAN Condicional (cGAN)

✦ Coloração Virtual (Project 9B)

✦ CycleGAN Não-Pareada

✦ Holo2Bright (Project 9C)

✦ Avaliação Downstream & Recall

A Estrutura Macro do Jogo Adversarial: Gerador vs Discriminador


O falsificador de cédulas contra o perito policial: O Discriminador como uma função de perda aprendível

Teoria dos Jogos de Soma Zero

O Jogo Minimax entre Gerador (Falsificador) e Discriminador (Polícia Investigativa)

Espaço Latente $z \sim N(0, I)$

Equilíbrio de Nash: $D(x) = 1/2$



PAPEL DO GERADOR

Aprender o Mapeamento Inverso

Transporta medida do espaço latente z para o espaço de dados reais

PAPEL DO DISCRIMINADOR

Guia Não-Paramétrico de Gradiente

Fornece o gradiente de supervisão que orienta as melhorias do Gerador

JOGO DE SOMA ZERO

Interdependência Mútua Dinâmica

Nenhum jogador pode melhorar sua estratégia unilateralmente no ótimo

A Anatomia Estrutural da DCGAN e Rastreamento de Tensores

Radford et al. (2015): Convoluções com stride, convoluções transpostas e o fluxo $[B, z] \rightarrow [B, C, H, W]$

Radford, Metz & Chintala (ICLR, 2016)


Arquitetura DCGAN (Deep Convolutional GAN): Rastreamento de Tensores de Ponta a Ponta

ConvTranspose2d


Strided Conv2d

LeakyReLU $\alpha=0.2$

TORRE DO GERADOR G(z): Expansão Espacial de Ruído Latente para Imagem Sintética



TORRE DO DISCRIMINADOR D(x): Compressão Espacial com Stride=2 e Extração de Features



🔥 As 5 Regras de Ouro de Radford et al. para Estabilidade da DCGAN:

1. Convoluções com stride (D) e convoluções transpostas (G) no lugar de pooling
2. BatchNorm em G e D (exceto saídas)
3. Remover camadas densas/lineares ocultas
4. ReLU em G com Tanh na saída
5. LeakyReLU ($\alpha=0.2$) em todas as camadas de D

TRANSPOSIÇÃO CONVOLUCIONAL

Upsampling com Parâmetros Treináveis

Fórmula de saída: $H_{out} = (H_{in} - 1) \cdot stride - 2 \cdot pad + kernel$

POR QUE LEAKY RELU EM D?

Prevenção de Neurônios Mortos

A inclinação $\alpha=0.2$ permite gradiente reverso mesmo quando a ativação é negativa

SEM POOLING ESPACIAL

Downsampling Aprendizível

Convoluções com stride=2 aprendem sua própria redução de dimensionalidade

Dinâmica de Treinamento Minimax e a Heurística Não-Saturante

Por que o gerador maximiza $\log D$ em vez de minimizar $\log(1 - D)$ para evitar gradientes mortos

Formalismo Matemático Rigoroso

Função de Valor Minimax, Discriminador Ótimo e a Heurística Não-Saturante de Goodfellow

JSD($p_{\text{data}} \parallel p_g$)Perda Não-Saturante: $-\log D$

1. A FUNÇÃO DE VALOR DO JOGO MINIMAX (Goodfellow, 2014)

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(G(z)))]$$

2. DERIVAÇÃO DO DISCRIMINADOR ÓTIMO $D^*(x)$ PARA G FIXO

Maximizando integrando $p_{\text{data}}(x) \log D(x) + p_g(x) \log(1 - D(x))$:

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$$

3. VALOR NO EQUILÍBRIO & DIVERGÊNCIA JENSEN-SHANNON

$$V(D^*, G) = -\log(4) + 2 \cdot D_{\text{JS}}(p_{\text{data}} \parallel p_g)$$

O mínimo global ocorre estritamente quando $p_g = p_{\text{data}}$, resultando em $D_{\text{JS}} = 0$, $V(D^*, G^*) = -\log 4 \approx -1.386$ e

DIVERGÊNCIA JENSEN-SHANNON

Simétrica e Limitada em $[0, \log 2]$ $D_{\text{JS}}(P \parallel Q) = 1/2 \text{KL}(P \parallel M) + 1/2 \text{KL}(Q \parallel M)$ onde $M = (P+Q)/2$

DISCRIMINADOR ÓTIMO

Razão Bayesiana de Densidades

 $D^*(x)$ estima a razão de densidade $p_{\text{data}}(x) / (p_{\text{data}}(x) + p_g(x))$


PADRÃO DA INDÚSTRIA

Perda Heurística Não-Saturante

Treina-se G maximizando $\log D(G(z))$ via BCE com rótulos 1.0 reais

DINÂMICA DE GRADIENTE DE G : SATURANTE vs NÃO-SATURANTE

Fix Prático Obrigatório



⚠ Por que Minimax Falha no Início?

Quando $D(G(z)) \approx 0$, a derivada de $\log(1 - D)$ tem inclinação plana, gerando desvanecimento total de gradiente em θ_g .

💡 A Solução de Engenharia:

Minimizar $-\log D(G(z))$ inverte a concavidade: mesmo ponto fixo de equilíbrio, mas fornece sinal de erro massivo para empurrar G rapidamente!



Laboratório Interativo: Dinâmica do Jogo Minimax e Gradientes

Simule em tempo real a curva do discriminador $D(x)$, compare as funções de perda e analise o vetor de gradiente

⏏

Controles da Simulação Minimax:

Separação p_{data} vs p_g (μ): 2.5 σ

Capacidade de D: 80%

Equilíbrio (Nash)

Início do Treino

DISTRIBUIÇÕES $p_{data}(x)$, $p_g(x)$ E SUPERFÍCIE $D^*(x)$

■ p_{data} (Real) ■ p_g (Gerado) — $D(x)$

$D(G(z)) = 0.13$

Divergência JS: 0.636

Valor $V(D^*, G)$: -0.114

Equilíbrio Nash: NÃO CONVERGIDO

DIAGNÓSTICO DO SINAL DE GRADIENTE DE G

Avaliando o gradiente efetivo quando o discriminador avalia amostras falsas em $D(G(z)) = 0.13$:

1. Perda Saturante: $\log(1 - D)$ Loss: -0.14

Magnitude do Gradiente de G: 13%⚠ Gradiente Nulo (Travado!)

2. Perda Não-Saturante: $-\log D$ (Padrão)Loss: 2.01

Magnitude do Gradiente de G: 87%⚡ Gradiente Vigoroso (Aprendendo)

💡 Insight de Engenharia:

No início do treinamento, o discriminador rejeita amostras com facilidade ($D \approx 0$). Sob a perda original $\log(1 - D)$, o gerador recebe quase zero de gradiente. A perda não-saturante $-\log D$ garante gradiente máximo de $1 - D \approx 1.0$, acelerando a convergência inicial!

FACULDADE INFNET

• Visão Computacional com CNNs e Transformers

N

 Falas

G

 Grid

F

 Tela Cheia

⬅

➡

 Mover

⏪

⏩

📄

🔍

⌂

Slide 5 / 15

O Limite da GAN Incondicional: Amostragem Cega e Colapso de Modos

Por que a GAN pura não escolhe a classe gerada e a armadilha de memorizar modos repetitivos

Patologia Clássica em GANs


A Anatomia do Colapso de Modos: Colapso Total, Colapso Parcial e a Dinâmica de "Mode Hopping"

Mode-Seeking Behavior

KL Reversa: $KL(p_g \parallel p_{data})$

1. DISTRIBUIÇÃO REAL p_{data}


8 Modos Distintos em Anel (Alta Diversidade)



Recall = 100% • Entropia Máxima
Todos os subespaços de dados representados

2. COLAPSO TOTAL DE MODOS

G aloca 100% da probabilidade no Modo M_1



Precision = 99% • Recall = 12.5% (1/8)
Amostras idênticas no batch • Perda de diversidade

3. O CICLO DE "MODE HOPPING"

G persegue um modo de cada vez sem convergir

Época 10 → G colapsa no Modo A

D ainda não sabe e é enganado por A; D_{loss} sobe

Época 12 → D aprende a rejeitar Modo A

$D(A) \rightarrow 0$. G sofre penalidade massiva em A

Época 15 → G salta inteiramente para o Modo B

G abandona A completamente; D é pego de surpresa

🔄 **Ciclo Infinito: G nunca aprende a diversidade simultânea!**

Causa Teórica: Assimetria da Divergência KL Reversa

$KL(p_g \parallel p_{data})$ penaliza severamente gerar fora do suporte (Mode Seeking)

COMPORTAMENTO MODE-SEEKING

A Falha de Foco Local

O gerador descobre um ponto fraco do discriminador e despeja toda massa ali

SINTOMA VISUAL NO TREINO

Batch Clone Syndrome

O grid de validação começa a exibir rostos ou objetos com traços e fundos idênticos

COMO DETECTAR QUANTITATIVAMENTE

Queda Abrupta no Recall

A métrica de Recall para modelos generativos despenca enquanto Precision se mantém

Solução Estrutural 1: GANs Condicionais (cGAN) & Coloração Virtual

Mirza & Osindero (2014) • Project 9B: Condicionamento de Marcadores em Neurônios Motores Humanos


Project 9B: Coloração Virtual de Tecidos Biológicos (Virtual Staining com cGAN)

Síntese Condicional sob Demanda (Human Motor Neurons)

1. Gerador Condicional: $G(z, y)$

Entrada Condicionada

Mapeamento de ruído latente e condição de biomarcador para tecido virtualmente corado.



- ✓ **Síntese Não-Destrutiva:** Descarta reagentes químicos tóxicos e fotobranqueamento.
- ✓ **Direcionamento Específico:** Gera a fluorescência exata do neurônio motor solicitado.

2. Discriminador Condicional: $D(x, y)$

Perito com Contexto

Avalia conjuntamente o fotorrealismo celular e a fidelidade ao marcador biológico solicitado.



- ✓ **Filtro Duplo:** Rejeita tecidos borrados E tecidos que apresentem o padrão celular errado.
- ✓ **Equilíbrio Minimax:** O gerador aprende a estrutura espacial precisa dos somas e axônios.

Objetivo Minimax Condicional: $\min_G \max_D V(D, G) = \mathbb{E}_{x, y \sim p_{data}} [\log D(x, y)] + \mathbb{E}_{z \sim p_z, y \sim p_y} [\log(1 - D(G(z, y), y))]$

Controle Estrutural de Síntese

Laboratório Interativo: Síntese Condicional & Coloração Virtual (Project 9B)

Altere os biomarcadores (DAPI vs NeuN vs GFP), ajuste a força do condicionamento e analise a telemetria de D(x, y)

 Laboratório Interativo: Virtual Staining com cGAN (Human Motor Neurons)

Project 9B • Coloração sob Demanda por Condição de Marcador

1. Selecionar Marcador Fluorescente (y):

DAPI (Núcleos Celulares)
y = 0

NeuN (Neurônios Motores)
y = 1

GFP (Axônios e Dendritos)
y = 2

Intensidade da Condição (y): 100%

 Amostrar Novo Tecido z (Seed #42)

Tecido Virtualmente Corado: $G(z, y_{neun})$

NeuN (Neurônios Motores)



Marcação celular específica do corpo celular (soma) de neurônios motores humanos.

Resposta do Discriminador D(x, y):

Realismo Celular Histológico: 95.4%

Correspondência com y = 1: 97.0%

Resultado Biológico: O modelo colore tecidos vivos digitalmente sem fixação química, gerando bancos de dados equilibrados para classificação celular.

O Dilema da Tradução de Imagens: Pix2Pix vs Realidade Não-Pareada

Por que não é possível alinhar células vivas sob múltiplos microscópios e a necessidade de tradução não-supervisionada

Engenharia de Estabilização
Avançada

Os 4 Pilares da Indústria para Treinamento Estável e Prevenção de Explosão de Gradientes

TTUR (Heusel
2017)

Spectral Norm (Miyato
2018)

1-Lipschitz
Contínuo

1. TTUR: Two Time-Scale Update Rule

Heusel et al. (NeurIPS 2017)

Uso de taxas de aprendizado assimétricas separadas no tempo:

$$\eta_D > \eta_G \quad (\text{ex: } \eta_D = 4 \times 10^{-4}, \eta_G = 1 \times 10^{-4})$$

Mecânica: Pela teoria de aproximação estocástica de Borkar, quando $\eta_G/\eta_D \rightarrow 0$, o gerador enxerga o discriminador como um sistema quase estático no ótimo local $D^*(x)$.

✓ Evita órbitas cíclicas caóticas e garante convergência estacionária.

2. One-Sided Label Smoothing

Salimans et al. (2016)

Suavização exclusiva dos rótulos reais para limitar a confiança de D:

$$y_{\text{real}} = 0.9 \quad \text{e} \quad y_{\text{fake}} = 0.0 \quad (\text{NUNCA } y_{\text{fake}} > 0!)$$

Por que unilateral? Se suavizarmos amostras falsas para 0.1, a fórmula ótima se torna $D(x) = \frac{0.9p_{\text{data}} + 0.1p_g}{p_{\text{data}} + p_g}$, forçando o discriminador a reforçar amostras ruins!

✓ Impede logits infinitos na sigmoid e estabiliza normas de gradiente.

3. Instance Noise (Injeção de Ruído)

Sønderby et al. (2016)

Engrossando artificialmente as variedades para forçar sobreposição:

$$\tilde{x} = x + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2 I), \quad \sigma_t \rightarrow 0$$

Mecânica: Adicionar ruído com annealing decrescente cria volumes estocásticos ao redor dos suportes disjuntos de $\mathcal{M}_{\text{real}}$ e $\mathcal{M}_{\text{fake}}$ permitindo gradientes não-nulos

CUSTO COMPUTACIONAL DO SN
Quase Zero Overhead

Power Iteration adiciona menos de 2% no tempo de treino por batch

CONDIÇÃO 1-LIPSCHITZ
Limite Superior nas Derivadas

Impede que gradientes $\|\nabla_x D\|$ explodam em descontinuidades locais

4. Spectral Normalization (SN-GAN)

Miyato et al. (ICLR 2018)

Controle estrito da constante de Lipschitz dividindo pela norma espectral:

$$W_{\text{SN}} = \frac{W}{\sigma(W)}, \quad \text{onde } \sigma(W) = \max_{h \neq 0} \frac{\|Wh\|_2}{\|h\|_2}$$

$\sigma(W)$

ca
ad
jro

APLICAÇÃO NO PYTORCH
Suporte Nativo Integrado

`torch.nn.utils.parametrizations.spectral_norm(conv_layer)`

Solução Estrutural 2: CycleGAN — Tradução de Domínio Sem Dados Pareados

Zhu et al. (2017) • Project 9C: Holo2Bright — Mapeamento Bidirecional Entre Holografia e Campo Claro

Project 9C: Conversão Entre Microscopia Holográfica e Campo Claro (Holo2Bright com CycleGAN)

Tradução Entre Modalidades Sem Pares Alinhados

Domínio X: Microscopia Holográfica

Sem Lentes • Amplo Campo

Amostra Real: $x \in X$

Padrões de difração e anéis de interferência de fase (ininteligíveis ao olho humano sem reconstrução numérica).

Discriminador D_X

Avalia se os hologramas são autênticos (x) ou sintetizados ($F(y)$).



Gerador $G : X \rightarrow Y \rightarrow$

Holograma $\rightarrow$ Campo Claro
Reconstrói morfologia celular e textura óptica

$\leftarrow$ Gerador $F : Y \rightarrow X$

Campo Claro $\rightarrow$ Holograma
Simula a propagação de onda óptica de fase

Domínio Y: Campo Claro (Bright-Field)

Padrão-Ouro Histológico

Amostra Real: $y \in Y$

Imagens com lentes objetivas: bordas celulares e organelas nítidas e familiares ao patologista.

Discriminador D_Y

Avalia se as imagens de campo claro são reais (y) ou sintetizadas por G ($G(x)$).



Por que não há pares? Células vivas movem-se e mudam de forma dinamicamente; registrar exatamente o mesmo campo sub-micrométrico em dois microscópios ópticos distintos é inviável na prática de laboratório!

Holo2Bright sem Pares

A Perda de Consistência de Ciclo: Preservação Morfológica em Holo2Bright

$x \rightarrow G(x) \rightarrow F(G(x)) \approx x$: Como o ciclo bidirecional impede distorções celulares e colapso de modos

Consistência de Ciclo (Cycle-Consistency Loss): Preservando a Morfologia Celular

Garantia Biunívoca Holografia ↔ Campo Claro

1. Ciclo Direto (Forward Consistency)

Holo → Bright → Holo

A imagem holográfica traduzida para campo claro deve ser perfeitamente revertida à holografia original.

x (Holograma)
Entrada Real



G(x)
Campo Claro Falso



F(G(x))
Reconstrução

Penalidade L1:

$$\mathcal{L}_{cyc}^{forward} = \mathbb{E}_{x \sim p(x)} [\|F(G(x)) - x\|_1]$$

✓ **Combate ao Colapso:** Se o gerador G mapear todos os hologramas em uma imagem fixa de célula bonita, o gerador reverso F jamais conseguirá recuperar as franjas de difração originais!

2. Ciclo Reverso (Backward Consistency)

Bright → Holo → Bright

A imagem de campo claro convertida em holograma deve retornar ao campo claro original.

y (Campo Claro)
Entrada Real



F(y)
Holograma Falso



G(F(y))
Reconstrução

Penalidade L1:

$$\mathcal{L}_{cyc}^{backward} = \mathbb{E}_{y \sim p(y)} [\|G(F(y)) - y\|_1]$$

✓ **Fidelidade Citológica:** Garante que o diâmetro, a membrana e o núcleo de cada célula permaneçam exatamente nas mesmas coordenadas espaciais.

★ **Perda de Identidade (Identity Loss):** $\mathcal{L}_{idt} = \mathbb{E}[\|G(y) - y\|_1 + \|F(x) - x\|_1]$ (Se a imagem já for Campo Claro, G não deve alterá-la!)

$\lambda_{cyc} = 10, \lambda_{idt} = 5$

Laboratório Interativo: Consistência de Ciclo no Holo2Bright (Project 9C)

Ajuste o peso λ_{cyc} e observe a transição entre colapso morfológico celular e reconstrução fiel

Laboratório Interativo: Consistência de Ciclo no Holo2Bright (Project 9C)

Regulagem do Hiperparâmetro λ_{cyc} para Preservação Citológica

1. Sentido da Tradução:

Holo $\rightarrow$ Bright $\rightarrow$ Holo

Bright $\rightarrow$ Holo $\rightarrow$
Bright

Peso do Ciclo (λ_{cyc}):

10



Perda de Ciclo (L1):

0.737


Distorção Citológica:

19%

✓ **Regime Ótimo ($\lambda=10$):** Tradução precisa de campo claro preservando as posições micrométricas e morfologia das células.


Fluxo Visual: Imagem Original $\rightarrow$ Traduzida $\rightarrow$ Reconstruída

1. Entrada Real x (Holograma)




Amostra de Entrada

2. Traduzida $G(x)$ [Campo Claro]



Fidelidade Óptica

3. Reconstruída $F(G(x))$



Recuperação Exata (L1 $\approx$ 0)

Fórmula Avaliada: $\|F(G(x)) - x\|_1$

O ciclo impede alucinação de artefatos celulares

Avaliação de Modelos Generativos: Do FID ao Impacto Downstream

Por que o realismo estatístico não basta: A validação mandatória pelo ganho de Recall na tarefa a jusante

Diagnóstico Quantitativo Rigoroso

Métricas de Avaliação de GANs: Inception Score (IS) vs Fréchet Inception Distance (FID)

Inception-v3 pool3 (d=2048)

Wasserstein-2 Gaussiano

1. INCEPTION SCORE (IS)

Salimans et al. (2016)

Mede simultaneamente a nitidez individual e a variedade marginal de classes:

$$IS(G) = \exp \left(\mathbb{E}_{x \sim p_g} [D_{KL}(p(y|x) \parallel p(y))] \right)$$

• **Nitidez da Amostra $p(y|x)$:** Cada imagem deve ter predição confiável e unívoca no classificador (baixa entropia condicional).

• **Diversidade de Classes $p(y)$:** A média marginal $p(y) = \frac{1}{N} \sum_i p(y|x_i)$ deve ser uniforme (alta entropia).

⚠ **Falha Crítica do IS:** O IS *não compara as amostras com o dataset de treino real*. Um modelo que memoriza apenas 1 imagem por classe do ImageNet obtém um IS excelente, mascarando completamente um colapso de modos severo dentro de cada classe.

2. FRÉCHET INCEPTION DISTANCE (FID)

Heusel et al. (NeurIPS 2017)

Distância Wasserstein-2 entre gaussianas no espaço de features InceptionV3 ('pool3', $D = 2048$):

$$FID = \|\mu_r - \mu_g\|_2^2 + \text{Tr} \left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2} \right)$$

Termo 1: Médias $\|\mu_r - \mu_g\|^2$

Distância euclidiana entre os centróides globais. Detecta desvio de cor, brilho, texturas médias e realismo global.

Termo 2: Traço das Covariâncias

Mede a dispersão espacial e diversidade. **Se houver Mode Collapse, Σ_g colapsa para matriz singular e o traço explode!**

★ **Por que o FID é o Padrão Ouro Internacional?** Quanto menor o valor do FID, mais próximas estão as distribuições real e sintética (FID = 0.0 é idêntico). Ele é altamente sensível a ruído gaussiano, borrões, perda de modos inteiros e artefatos de grade.

PROTOCOLO DE AMOSTRAGEM FID

50.000 Imagens Mínimas

FID em batches pequenos (< 10k) sofre de viés amostral positivo artificial

CALCANHAR DE AQUILES DO FID

Hipótese Gaussiana Rígida

Assume que as 2048 dimensões de ativação seguem uma normal multivariada

A SOLUÇÃO MODERNA

Precision and Recall

Desacopla nitidez visual de cobertura de diversidade sem hipótese gaussiana



Laboratório Interativo: Impacto no Recall Downstream com Augmentation Generativa

Simule a adição de amostras sintéticas de classes raras e observe a queda de Falsos Negativos e o salto no Recall

Laboratório Interativo: Avaliação do Impacto no Recall Downstream com Augmentation Generativo Teste Real: 850 Amostras Típicas + 150 Fenótipos Raros (100% Imagens Reais)

Amostras Sintéticas da Classe Rara: **+0 imgs**



0 (Baseline Sem GAN) 1500 (+Balanceado) 3000 (Aumentado)

Recall (Sensibilidade):
58.0%
Meta diagnóstica: ≥ 90%

Falsos Negativos (FN):
63 casos
Casos não detectados

Precisão:
67.4%
F1-Score: 0.62

Especificidade:
95.1%
Acurácia: 89.5%

Risco Crítico de Triagem: 63 casos da classe minoritária ignorados pelo classificador! Acurácia de 89.5% mascara a falha grave.

Matriz de Confusão no Teste Real (1.000 Lâminas/Amostras)

Baseline (Sem Augmentation)

	Previsto: Típico	Previsto: Raro
Real: Típico (850)	808 Verdadeiro Negativo (TN)	42 Falso Positivo (FP)
Real: Raro (150)	63 Falso Negativo (FN) ⚠	87 Verdadeiro Positivo (TP)

Fórmula do Recall: $Recall = \frac{TP}{TP+FN}$

Geração sintética equilibra a distribuição a jusante

Quiz Formativo de Fixação: GANs Estruturais, cGAN, CycleGAN e Métricas de Impacto

Avalie seus conhecimentos com 4 questões práticas e conceituais abordando Projects 9B, 9C e avaliação downstream

? Quiz Formativo de Fixação • GANs Estruturais, cGAN, CycleGAN e Impacto Clínico

Questão 1 de 4 • Pontuação: 0/4

Questão 1 • Dinâmica de Gradientes Minimax & Heurística Não-Saturante

No treinamento de uma DCGAN, por que substituímos a minimização da função original $\log(1 - D(G(z)))$ pela maximização de $\log D(G(z))$ (ou minimização de $-\log D$) para atualizar o gerador?

- A Porque a formulação original possui mínimo em um ponto diferente do Equilíbrio de Nash.
- B Porque no início do treino, quando D rejeita fakes com facilidade ($D \approx 0$), a função original satura com gradiente nulo, enquanto $-\log D$ provê gradientes vigorosos.
- C Porque $\log D$ dispensa a necessidade de retropropagar gradientes através das camadas do discriminador.
- D Porque $\log D$ garante automaticamente que a rede do discriminador seja 1-Lipschitz contínua.

Confirmar Resposta