

Avaliação de Modelos Generativos (FID) e Síntese Teórica da Disciplina

Fréchet Inception Distance, Interpretabilidade, Multimodalidade e Metodologia Rigorosa de Projetos

Etapa Final / Aula 08

Faculdade Infnet • Pós-Graduação em Visão Computacional com CNNs e Transformers

✦ Fréchet Inception Distance (FID)

✦ Inception-v3 pool3 (2048-D)

✦ 6 Marcos Arquiteturais do Curso

✦ Vision Transformers & Attention Maps

✦ Espaço Latente Multimodal CLIP

✦ Transfer Learning & Augmentation

✦ Oversampling Generativo cGAN/CycleGAN

✦ Governança Sem Vazamento de Dados



Estrutura Pedagógica: Dos Fundamentos do FID à Síntese Teórica

Quatro blocos estruturados articulando avaliação estatística, evolução arquitetural, interpretabilidade e governança

Bloco 1

Estatística Multivariada

Métrica FID & Avaliação de GANs

Slides 03 a 06

- ✓ Falhas de MSE, PSNR e Inception Score (IS)
- ✓ Extração de Features no Inception-v3 (pool3, R^2048)
- ✓ Simulador Interativo do FID & Álgebra de Fréchet
- ✓ Boas Práticas de Engenharia e Reprodutibilidade (clean-fid)

Pilar Teórico 1 da Disciplina

Bloco 2

Conexão Evolutiva

Evolução Arquitetural: 6 Marcos

Slides 07 a 12

- ✓ Marco 1: CNNs (ResNet) & U-Net (Resíduos e Skips)
- ✓ Marco 2: O Transformer Canônico & BERT (MHA e [CLS])
- ✓ Marco 3: Vision Transformer (ViT) & Patch Slicing 16×16
- ✓ Marco 4: Swin Transformer (Pirâmide e Janelas Deslocadas)
- ✓ Marco 5: CLIP (Dual-Encoder e Hiperesfera S⁵¹¹)
- ✓ Marco 6: Modelos Generativos & U-Net de Difusão Latente

Pilar Teórico 2 da Disciplina

Bloco 3

Laboratórios & Auditoria

Interpretabilidade & Multimodalidade

Slides 13 a 16

- ✓ Extração de Attention Maps do [CLS] e Reshape Espacial
- ✓ Laboratório Interativo: Auditoria de Atenção e Atalhos
- ✓ Calibração de Thresholds e Concentração Geométrica em CLIP
- ✓ Laboratório Interativo: Busca Semântica por Níveis de Abstração

Pilar Teórico 3 da Disciplina

Bloco 4

Metodologia e Métricas

Governança & Validação Científica

Slides 17 a 23

- ✓ Feature Extraction vs Fine-Tuning de Grafo Completo
- ✓ Taxonomia e Riscos Semânticos de Data Augmentation
- ✓ Paradoxo da Acurácia, Balanced Accuracy e Primazia do Recall
- ✓ Oversampling com cGAN/CycleGAN e Teste 100% Real
- ✓ Vazamento por Grupos (GroupKFold) e Quiz de Fixação

Pilar Teórico 4 da Disciplina

O Dilema da Avaliação Generativa: Por que MSE e Inception Score Falham

A ausência de alinhamento pixel a pixel e as fragilidades estruturais do Inception Score

DILEMA METODOLÓGICO

Por que Métricas Supervisionadas e Inception Score Falham na Avaliação de Redes Generativas

Sem Pares 1:1

Vulnerabilidade do IS

1. Falha das Métricas Pixel a Pixel

Inaplicável a GANs

Métricas clássicas como MSE, PSNR e SSIM exigem alinhamento pixel a pixel exato entre uma entrada e um alvo de referência (ground-truth).

$$\text{MSE} = \frac{1}{H \times W \times C} \sum_{i,j,k} (I_{\text{real}}(i, j, k) - I_{\text{gen}}(i, j, k))^2$$

• Inexistência de Par Ground-Truth:

Modelos gerativos amostram de ruído $z \sim \mathcal{N}(0, I)$ para criar novas instâncias plausíveis. Não existe uma imagem real idêntica pré-definida para comparar.

• Sensibilidade a Deslocamentos Espaciais:

Uma imagem gerada perfeitamente fotorrealista com um deslocamento de apenas 2 pixels gera um MSE massivo, penalizando o modelo mesmo com realismo impecável.

⚠ **Conclusão:** É mandatório comparar distribuições estatísticas no espaço latente, nunca pixels individuais.

2. Vulnerabilidades Críticas do Inception Score (IS)

Salimans et al. (2016)

$$\text{IS}(G) = \exp \left(\mathbb{E}_{x \sim p_g} [D_{\text{KL}}(p(y|x) \parallel p(y))] \right)$$

Falha 1 Ausência de Comparação com Dados Reais

O IS avalia apenas as previsões do classificador Inception-v3 sobre as imagens sintéticas. Não mede se a distribuição gerada p_g é similar aos dados reais p_{data} .

Falha 2 Cegueira ao Colapso de Modo Intra-Classe

Se o gerador memorizar e sintetizar exatamente uma única imagem perfeita para cada classe, $p(y)$ será perfeitamente uniforme e o IS será altíssimo, mascarando ausência total de diversidade.

Falha 3 Vieses Estritos de Categorias ImageNet

A rede Inception foi treinada em 1.000 classes gerais (animais, veículos). Em domínios técnicos (imagens médicas, satélite, texturas), a probabilidade $p(y|x)$ perde sentido discriminativo.

💡 **Solução:** O Fréchet Inception Distance (FID) compara as estatísticas completas das features contínuas!

A Engenharia do FID: Extração de Features no Espaço Latente Inception-v3

Mapeamento de distribuições visuais de alta dimensão para representações semânticas contínuas em $\mathbb{R}^{2048}$

ARQUITETURA DE EXTRAÇÃO

Pipeline do FID: Mapeamento de Imagens em Representações Latentes no Inception-v3 (pool3)

Inception-v3 (pool3)

Espaço Contínuo $\mathbb{R}^{2048}$

Heusel et al. (2017)

Imagens Reais (p_data)
N amostras [N, 3, 299, 299]



Inception-v3 (Congelado)
Camada Global Average Pooling
pool3 (2048 canais)



Embeddings Reais
 $F_r \in \mathbb{R}^{(N \times 2048)}$
Ativações semânticas contínuas



Distribuição Gaussiana Real
 $\mu_r \in \mathbb{R}^{2048}, \Sigma_r \in \mathbb{R}^{2048 \times 2048}$
Média empírica e covariância

Comparação de Distribuições Multivariadas: $d^2(\mathcal{N}(\mu_r, \Sigma_r), \mathcal{N}(\mu_g, \Sigma_g))$

Imagens Sintéticas (G(z))
N amostras [N, 3, 299, 299]



Inception-v3 (Mesmos Pesos)
Camada Global Average Pooling
pool3 (2048 canais)



Embeddings Sintéticos
 $F_g \in \mathbb{R}^{(N \times 2048)}$
Ativações geradas pelo modelo



Distribuição Gaussiana Sintética
 $\mu_g \in \mathbb{R}^{2048}, \Sigma_g \in \mathbb{R}^{2048 \times 2048}$
Média empírica e covariância

1. Abstração Semântica

A camada 'pool3' captura conceitos estruturais (partes de objetos, contornos, iluminação), descartando variações triviais de pixels.

2. Suposição Gaussiana

Embora o espaço de features não seja perfeitamente gaussiano, a aproximação multivariada é analiticamente tratável e robusta na prática.

3. Resolução Padrão

Todas as imagens são redimensionadas para 299×299 antes do Inception-v3 com interpolação bicúbica consistente.

Laboratório Interativo: Simulador Paramétrico da Distância de Fréchet

Manipule centroides, dispersão de covariância e modos de colapso para visualizar o impacto no FID em tempo real

LAB INTERATIVO

Simulador Paramétrico da Distância de Fréchet (FID)

✓ Ideal

⚠ Mode Collapse

⚡ Deslocamento Média

🌀 Ruído/Dispersão

Parâmetros da Distribuição G(z)

Ajuste as características estatísticas das features geradas:

1. Deslocamento de Média ($\Delta\mu$): 0.20



0 = centroides idênticos; 3 = forte viés semântico

2. Escala de Variância (σ_g / σ_r): 1.00x



< 0.3 = colapso de modo; 1.0 = dispersão ideal; > 1.8 = ruído

3. Rotação de Covariância (θ): 0°




Desalinhamento da correlação cruzada entre canais

💡 O FID agrega tanto o deslocamento de média quanto as falhas de covariância em uma única métrica escalar.

Projeção do Espaço de Features (Gaussiana 2D)

● Real $N(\mu_r, \Sigma_r)$ ● Sintético $N(\mu_g, \Sigma_g)$



Decomposição Numérica

FRÉCHET INCEPTION DISTANCE

2.14

Escala normalizada (Menor é melhor)

$\|\mu_r - \mu_g\|^2$: 2.14

$\text{Tr}(\Sigma_r + \Sigma_g - 2\sqrt{\cdot})$: 0

Excelente Equilíbrio (Fidelidade & Diversidade)

O gerador aprendeu a média das características e preserva toda a dispersão estatística do dataset real.

Baseado na formulação matemática de Heusel et al. (NeurIPS 2017)

Práticas de Engenharia do FID: Tamanho Amostral, Viés e Padronização

Diretrizes metodológicas para evitar medições espúrias e garantir reprodutibilidade experimental

BOAS PRÁTICAS DE ENGENHARIA

Diretrizes Metodológicas do FID: Tamanho Amostral, Reprodutibilidade e Precision vs Recall

Viés Amostral N

clean-fid

Precision & Recall

1. O Viés Amostral Positivo (N)

Viés $O(1/N)$

O estimador empírico do FID possui um viés matemático sistemático para conjuntos de amostras pequenos.

$$\mathbb{E}[\text{FID}_N] = \text{FID}_\infty + \frac{c}{N}$$

- **N = 1.000:** O FID medido é artificialmente inflado em 10 a 20 pontos mesmo para distribuições idênticas.
- **N = 10.000:** Mínimo aceitável para prototipagem rápida e acompanhamento de curvas.
- **N = 50.000:** Padrão ouro mandatório na literatura científica (FID_{50k}) para estabilização assintótica.

⚠ Regra: Sempre reporte o tamanho exato de amostras N ao publicar ou comparar scores de FID.

2. Reprodutibilidade & clean-fid

Parmar et al. (2022)

Pequenas diferenças operacionais no pipeline de entrada corrompem drasticamente o valor absoluto do FID:

• Algoritmo de Rescaling:

Bilinear vs Bicúbico altera o FID em até 5 a 8 pontos para o mesmo modelo exato!

• Biblioteca de Imagem:

Decodificação via PIL, OpenCV ou PyTorch gera pequenas discrepâncias de quantização.

• Solução Padronizada:

Utilizar bibliotecas consagradas como **torch-fidelity** ou **clean-fid** com pesos Inception-v3 idênticos.

🛡 Boas Práticas: Armazene estatísticas pré-computadas (μ_r, Σ_r) do conjunto real para acelerar execuções.

3. Precision vs Recall de Variedades

Sajjadi / Kynkäänniemi

O FID resume tudo em um único número. Para diagnóstico refinado, decompõe-se em duas métricas ortogonais:

Precision (Fidelidade):

Qualidade

Fração das imagens geradas que caem dentro do suporte da variedade de dados reais (ausência de alucinações irreais).

Recall (Diversidade):

Cobertura

Fração da variedade de dados reais coberta pelas amostras geradas (sensível a mode collapse e omissão de classes).

💡 Insight: Um modelo pode ter alta Precision gerando apenas poucas imagens nítidas, mas terá baixo Recall!

Marco 1 – CNNs Profundas (ResNet) & U-Net: A Era dos Convolutivos e Conexões Residuais

A superação da degradação de gradientes via atalhos residuais e a preservação de detalhes espaciais na U-Net

MARCO 1 / 6

CNNs Profundas (ResNet) & U-Net: A Era dos Convolutivos e Conexões Residuais

1. CNN / U-Net

→ 2. Transformer

→ 3. ViT


→ 4. Swin

→ 5. CLIP

→ 6. Difusão/GAN

● ResNet: O Atalho Residual $x + F(x)$


He et al. (CVPR 2016)



Inovação Central: Permitiu treinar redes com 50, 101 e 152 camadas sem degradação, onde o atalho de identidade garante fluxo ininterrupto de gradientes até as primeiras camadas.

● U-Net: Encoder-Decoder Simétrico com Skips

Ronneberger et al. (MICCAI 2015)



Inovação Central: A combinação de contração e expansão com pontes de atalho copiou detalhes anatômicos e de pixel diretamente para a saída, tornando-se a base de segmentação e de ****modelos de difusão****.



O ELO DE LIGAÇÃO COM O PRÓXIMO MARCO:

Filtros 3×3 possuem **viés indutivo estritamente local**. Para capturar relações globais em sequências longas e entre pontos distantes da imagem sem empilhar dezenas de convoluções, surge a **Auto-Atenção Pura (Transformers)**.

Avanço: Convolução Local → Auto-Atenção Global →

Marco 2 — O Transformer Canônico & BERT: O Advento da Auto-Atenção Global e Encoders


Projeções Query-Key-Value, matrizes de contexto e o token [CLS] como agregador de sequência

MARCO 2 / 6 O Transformer Canônico & BERT: O Advento da Auto-Atenção Global e Encoders

1. CNN / U-Net → 2. Transformer / BERT → 3. ViT → 4. Swin → 5. CLIP → 6. Difusão/GAN

Multi-Head Attention (MHA) & Bloco Transformer

Vaswani et al. (NeurIPS 2017)



Inovação Central: A atenção calcula dinamicamente pesos cruzados entre quaisquer pares de tokens, permitindo paralelização massiva de treinamento em GPU sem a limitação sequencial de RNNs.

BERT: O Encoder Bidirecional & Token [CLS]

Devlin et al. (NAACL 2019)



Inovação Central: Introduziu o token especial [CLS] na posição 0 como vetor resumo da sequência e a filosofia moderna de pré-treino auto-supervisionado com fine-tuning downstream.

 O ELO DE LIGAÇÃO COM O PRÓXIMO MARCO:

O Transformer funcionou para sequências 1D de texto; mas em imagens 2D, pixels gerariam matrizes de atenção proibitivas $O(N^2)$. A solução de engenharia? **Fatiar imagens em Patches Discretos de 16x16 (ViT)!**

Avanço: Tokens de Texto → Fatiamento em Patches Visuais →

Marco 3 — Vision Transformer (ViT): A Conquista da Atenção Pura em Visão sem Convoluções

Fatiamento de imagens em patches de 16×16 , projeção linear de embeddings e campo receptivo global imediato

MARCO 3 / 6

Vision Transformer (ViT): A Conquista da Atenção Pura em Visão sem Convoluções

1. CNN / U-Net →

2. Transformer →

3. ViT Canônico


→ 4. Swin →

5. CLIP →

6. Difusão/GAN

● Fatiamento em Patches & Projeção Linear


Dosovitskiy et al. (ICLR 2021)



Inovação Central: Trata a imagem exatamente como palavras no NLP. Remove o viés indutivo de localidade convolucional; ganha capacidade representacional ilimitada quando pré-treinado em escala massiva (JFT-300M).

● Pilha de Encoders & Head [CLS]

ViT-Base (12 Layers, 86M Parâmetros)



Inovação Central: O mecanismo de auto-atenção global estabelece conexões diretas entre qualquer par de patches na camada 1, obtendo um campo receptivo global instantâneo impossível em CNNs convencionais.



**O ELO DE LIGAÇÃO
COM O PRÓXIMO
MARCO:**

O ViT é global, mas seu custo computacional é quadrático $O(N^2)$ e sua resolução espacial é estática (sem pirâmide multiescala), inviabilizando segmentação densa e alta resolução. A solução de engenharia? **O Swin Transformer com Janelas Deslocadas e Pirâmide Hierárquica!**

Avanço: Atenção Global Quadrática → Janelas Deslocadas Lineares →

Marco 4 — Swin Transformer: Hierarquia Piramidal e Janelas Deslocadas Lineares


Patch Merging em 4 estágios e atenção local W-MSA/SW-MSA com complexidade linear

MARCO 4 / 6 Swin Transformer: Hierarquia Piramidal e Janelas Deslocadas Lineares

1. CNN / U-Net → 2. Transformer → 3. ViT → 4. Swin Transformer → 5. CLIP → 6. Difusão/GAN

● Pirâmide Multiescala & Patch Merging


Liu et al. (ICCV 2021 Best Paper)



Inovação Central: Resgata a estrutura piramidal hierárquica das CNNs via *Patch Merging* (reduz resolução em $2 \times$ e dobra canais), tornando-se compatível direto com FPN, U-Net e Mask R-CNN.

● Janelas Deslocadas: W-MSA → SW-MSA

Complexidade Linear $O(M^2 \cdot N)$



Inovação Central: Calcula auto-atenção apenas dentro de janelas locais de tamanho fixo $M \times M$ ($M = 7$). O deslocamento na camada seguinte permite comunicação entre janelas mantendo custo estritamente linear $O(M^2 \cdot N)$.



O ELO DE LIGAÇÃO
COM O PRÓXIMO
MARCO:

O Swin otimizou o custo linear e a multiescala em visão, mas ainda dependia de rótulos categóricos fechados (ex: 1.000 classes do ImageNet). A solução de engenharia? **O CLIP: Unificação Multimodal Visão-Linguagem via Aprendizado Contrastivo em Hiperesfera!**

Avanço: Classes Fixas → Espaço Semântico Aberto Zero-Shot →

Marco 5 – CLIP: Alinhamento Multimodal Visão-Texto e Aprendizado Zero-Shot


Arquitetura dual-encoder, projeção em hiperesfera unitária S^{511} e otimização contrastiva InfoNCE

MARCO 5 / 6 CLIP: Alinhamento Multimodal Visão-Texto e Aprendizado Zero-Shot

1. CNN / U-Net → 2. Transformer → 3. ViT → 4. Swin → 5. CLIP → 6. Difusão/GAN

Arquitetura Dual-Encoder & Hiperesfera S^{511}


Radford et al. (OpenAI 2021)



Inovação Central: Desacoplamento modal com projeção em hiperesfera unitária de 512 dimensões. Elimina cabeças de classificação pré-fixadas e viabiliza classificação *Zero-Shot* em qualquer vocabulário.

Matriz de Similaridade & Perda InfoNCE

400M Pares (WIT Dataset)



Inovação Central: Otimização contrastiva simultânea em batch de $N \times N$ pares: alinha pares verdadeiros na diagonal e repele todos os pares falsos, produzindo representações semânticas robustas e transferíveis.

O ELO DE LIGAÇÃO COM O PRÓXIMO MARCO:

O CLIP conecta texto e imagem para busca e discriminação; mas como ****gerar imagens realistas inéditas a partir de descrições textuais****? A solução de engenharia? **Modelos Generativos & U-Net de Difusão Latente condicionada por Cross-Attention do CLIP!**

Avanço: Alinhamento Discriminativo → Síntese Generativa de Pixels →



Marco 6 – Modelos Generativos & Difusão: A Grande Convergência Arquitetural do Curso

A U-Net de difusão latente integrando convoluções residuais, cross-attention e atenção temporal


● Evolução: De GANs à Difusão Latente (LDM)

Rombach et al. (CVPR 2022)



● A U-Net de Difusão: Síntese de Todas as Aulas

Convergência do Curso



Inovação Central: A U-Net de difusão é a obra-prima unificadora do curso: integra convoluções residuais (Aula 1), atenção multi-head espacial e multiescala (Aulas 2 a 4), condicionamento CLIP (Aula 6) e atenção temporal (Aula 7).

SÍNTESE DO ECOSISTEMA DA DISCIPLINA:

Cada arquitetura respondeu a um gargalo do mundo real: **ResNet/U-Net** superaram a degradação; **Transformers/ViT** romperam o campo receptivo estático; **Swin** garantiu escala linear; **CLIP** abriu o vocabulário para a linguagem; e a **Difusão** unificou tudo para criar imagens do zero!

Jornada Completa: Da Convolução à Difusão Latente ✓

Interpretabilidade em ViT: Extração e Visualização de Mapas de Atenção

Como dissecar a matriz de atenção QK^T para inspecionar onde o classificador foca seu raciocínio

INTERPRETABILIDADE & AUDITORIA

Extração de Attention Maps no ViT: Da Matriz de Atenção ao Heatmap Sobreposto

Token [CLS] Linha 0

Reshape [14 × 14]

Auditoria de Atalhos

Passo 1 hook / return_weights

Extração da Matriz A

$$A = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right)$$

Tensor de atenção da última camada: [B, h, 197, 197] com h cabeças.



Passo 2 A[:, head, 0, 1:]

Isolamento do [CLS]

$$w_{\text{cls}} \in \mathbb{R}^{196}$$

Linha 0 representa o peso que o classificador atribui a cada um dos 196 patches espaciais (descarta o índice 0 de auto-atenção).



Passo 3 .view(14, 14)

Reshape & Interpolação

$$[196] \rightarrow [14, 14] \xrightarrow{\text{bilinear}} [224, 224]$$

Reconstitui a grade bidimensional espacial e faz upsampling contínuo para resolução da imagem.



Passo 4 colormap + overlay

Heatmap & Diagnóstico

Auditoria de Justificativa

Sobreposição transparente (alpha=0.5) para auditar se o modelo foca no objeto relevante ou em artefatos de fundo.

🎯 Atenção Semântica Válida (Alta Confiança)

Os picos de atenção concentram-se estritamente sobre as bordas morfológicas e elementos centrais do objeto discriminado. O modelo generalizará bem para novos ambientes e sensores.

⚠️ Atenção Espúria (Shortcut Learning / Vazamento)

O mapa de atenção foca em marcas d'água, cantos escuros, etiquetas ou texturas de fundo. O modelo aprendeu um atalho correlacional em vez da causa visual real, falhando fora do treino.

📄 Implementação PyTorch: Registre um `register_forward_hook` no módulo `encoder.layers[-1].self_attention` para interceptar a matriz sem alterar o grafo.

`model.encoder.layers[-1]`

Laboratório Interativo: Inspetor de Mapas de Atenção do Vision Transformer

Explore a distribuição de atenção por cabeça e camada para auditar a interpretabilidade do modelo

LAB INTERATIVO

Inspetor de Mapas de Atenção do Vision Transformer (ViT-B/16)

Objeto Saliente

Cena Complexa

⚠ Caso com Atalho

Configuração da Auditoria

1. Profundidade do Encoder:

Camada 1

Camada 6

Camada 12

Camada 12 (Profunda) — Conceito Global [CLS]

2. Cabeça de Atenção (Head):

H1

H2

H3

H4

Média

Attention Rollout (todas as 12 cabeças)


Opacidade da Sobreposição:

65%

💡 Inspeccionar cabeças individuais revela se o modelo divide o trabalho (ex: H1 bordas, H2 semântica central, H3 contexto).

Visualização Espacial dos 196 Patches (14 × 14)

Resolução: 224 × 224



Diagnóstico de Atenção

Fidelidade Alta

Atenção Semântica Focalizada no Alvo

O token [CLS] pondera fortemente os patches correspondentes à anatomia/morfologia discriminante do objeto central.

Entropia de Atenção: 1.84 nats (Focalizada)

Patches Acima de 2σ : 24 / 196 (Centroide)

📝 **Requisito do Projeto:** Documente e interprete por escrito o que os attention weights de ao menos uma cabeça revelam no seu domínio de aplicação.

Busca Semântica com CLIP: Calibração de Thresholds e Prompt Engineering

Como estruturar rankings de similaridade de cosseno e calibrar pontos de corte em espaços de alta dimensão

BUSCA SEMÂNTICA & DECISÃO

Mecânica de Retrieval do CLIP: Calibração de Thresholds e Engenharia de Prompts

Ranking Top-K

Calibração de Limiar

Do Concreto ao Abstrato

1. Geometria em Alta Dimensão

Concentração de Medida

No espaço latente $\mathbb{R}^{512}$, vetores ortogonais aleatórios possuem similaridade próxima a zero, mas pares imagem-texto não-correlacionados concentram-se em uma faixa estreita:

Faixa Típica de Ruído de Fundo:
 $0.12 \leq S_{\text{cosseno}} \leq 0.22$

- **Erro Comum de Iniciantes:** Esperar que similaridades variem de 0.0 a 1.0 como probabilidades.
- **Alinhamento Fraco:** Scores entre 0.20 e 0.24 indicam vaga associação semântica.
- **Alinhamento Forte:** Scores ≥ 0.28 indicam alta correspondência conceitual.

📌 **Nota:** A similaridade de cosseno reflete ângulo angular, não probabilidade calibrada de classe.

2. Calibração de Thresholds

Ponto de Corte Justificado

Para decidir se um objeto ou conceito está presente em uma imagem, define-se um limiar de corte τ :

Threshold Alto (ex: $\tau = 0.30$):

Alta Precisão

Retorna apenas detecções inequívocas, mas gera Falsos Negativos (baixo Recall).

Threshold Baixo (ex: $\tau = 0.22$):

Alto Recall

Recupera a maioria das ocorrências, mas sofre com Falsos Positivos causados pelo ruído de fundo.

🎯 **Critério Científico:** O threshold deve ser calibrado com base no percentil 95% de pares negativos aleatórios.

3. Espectro de Consultas (Prompts)

Engenharia Semântica

O Text Encoder responde diferentemente conforme o nível de abstração da formulação textual:

• Consultas Concretas:

"a photo of a red bicycle" → Ativações nítidas baseadas em geometria e cores literais.

• Consultas Abstratas:

"healthy lifestyle and wellness" → Depende de correlações culturais e contexto indireto aprendido no pré-treino.

• Templates de Contexto:

Usar prefixos como "a clear photo of [objeto]" estabiliza os embeddings.

💡 **Análise Crítica:** Sempre compare se o modelo recupera o sentido literal ou faz associações espúrias.

Laboratório Interativo: Busca Semântica e Calibração de Thresholds com CLIP

Teste consultas textuais variando em abstração, calibre o limiar de similaridade e avalie a recuperação semântica

LAB INTERATIVO

Simulador de Busca Semântica e Calibração de Thresholds no CLIP

Consulta Concreta (Carro)

Consulta Técnica (Microscopia)

Consulta Abstrata (Liberdade)

Consulta em Linguagem Natural

CONCRETA / OBJETO ESPECÍFICO

"a photo of a modern sports car on a highway"

Limiar de Corte (Threshold τ): 0.25

0.15 (Permissivo / Alto Recall) 0.33 (Rigorous / Alta Precisão)

i Apenas imagens com similaridade $S \geq \tau$ são consideradas detecções positivas da consulta textual.

Baseado no modelo CLIP ViT-B/32 com embeddings normalizados L2.

Ranking Ordenado por Similaridade de Cosseno (Top-6)

Recuperados: 2 de 6

#1

RECUPERADO

**Carro Esportivo Vermelho**

Carro em alta velocidade

Score cos:

0.34

#2

RECUPERADO

**Rodovia Movimentada**

Estrada com veículos

Score cos:

0.29

#3

REJEITADO

**Motocicleta na Pista**

Veículo sobre rodas de 2 eixos

Score cos:

0.24

#4

REJEITADO

**Avião Decolando**

Meio de transporte aéreo

Score cos:

0.19

#5

REJEITADO

**Interior de Escritório**

Mesa e computadores

Score cos:

0.16

#6

REJEITADO

**Paisagem Florestal**

Árvores e montanhas

Score cos:

0.13

Métricas do Retrieval

Precisão: 100.0%

Acertos / Total Recuperados (2/2)

Recall (Cobertura): 100.0%

Acertos / Relevantes Existentes (2/2)

Falsos Positivos: 0
Falsos Negativos: 0

Diretriz do Projeto: Ao implementar busca semântica, varie o threshold e documente as imagens recuperadas para ao menos 8 consultas distintas.

Transfer Learning em CNNs: Feature Extraction vs Fine-Tuning de Grafo Completo

Diferenciação estrutural de grafos computacionais, fluxo de gradientes e gerenciamento de capacidade

REVISÃO TEÓRICA III

Transfer Learning em CNNs: Feature Extraction vs Fine-Tuning de Grafo Completo

requires_grad = False

AdaptiveAvgPool2d

Taxas Diferenciais

1. Feature Extraction (Backbone Congelado)

Ideal para Pequenos Datasets

Todas as camadas convolucionais pré-treinadas têm seus gradientes desativados. Treina-se estritamente a nova camada linear de saída:

Backbone Convolucional (ResNet-50)

Congelado ($\nabla \theta = 0$)Global Average Pooling [B, 2048, 1, 1] $\rightarrow$ [B, 2048]Novo Head: `nn.Linear(2048, C)`

Treinável (Gradientes Ativos)

✓ **Zero Esquecimento Catastrófico:** Os filtros de alta qualidade do ImageNet permanecem intactos.

⚡ **Velocidade & Eficiência de VRAM:** Pode-se pré-extrair as features para a RAM/GPU e treinar apenas o classificador em segundos.

🛡️ **Prevenção de Overfitting:** Reduz dramaticamente a contagem de parâmetros treináveis (apenas $2048 \times C$ pesos).

```
for param in model.parameters(): param.requires_grad = False
model.fc = nn.Linear(model.fc.in_features, num_classes)
```

2. Fine-Tuning (Ajuste Fino Parcial ou Total)

Adaptação a Novos Domínios

Descongelam-se blocos convolucionais profundos (ex: Layer4 da ResNet) para reajustar filtros semânticos com taxas de aprendizado baixas:

Camadas Iniciais (Bordas e Cores Gerais)

Congeladas

Feedforward

Blocos Profundos + Novo Head Linear

Taxas Diferenciais

🎯 **Especialização de Domínio:** Re-orienta a representação interna se os dados divergirem do ImageNet (ex: satélite ou microscopia).

⚠️ **Risco de Destruição de Pesos:** Se η for muito alto, gradientes ruidosos destroem a inicialização útil.

⚙️ **Regra de Ouro:** $\eta_{\text{backbone}} \approx 10^{-5} \ll \eta_{\text{head}} \approx 10^{-3}$.

```
optimizer = AdamW([
    {'params': model.layer4.parameters(), 'lr': 1e-5 },
    {'params': model.fc.parameters(), 'lr': 1e-3 }
])
```



Estratégias de Data Augmentation: Racional Teórico vs Riscos de Corrupção Semântica

A fundamentação teórica de por que transformações cegas podem destruir o aprendizado de representações

TAXONOMIA & ANÁLISE CRÍTICA

Estratégias de Data Augmentation: Racional Teórico vs Riscos de Corrupção Semântica

Invariância Afim

Fotometria

Preservação de Rótulo

1. Aumentações Geométricas

Invariância Espacial

```
RandomHorizontalFlip(p=0.5)
RandomRotation(degrees=15)
RandomResizedCrop(224, scale=(0.8, 1.0))
```

✓ Quando é Benéfico:

Objetos naturais ou cenas gerais onde a pose, enquadramento ou escala não alteram a identidade de classe.

⚠ Risco de Corrupção Semântica:

Flips verticais/horizontais em imagens médicas com assimetria anatômica (ex: coração à esquerda) ou símbolos orientados (dígitos 6 e 9, setas direcionais).

Regra: Nunca aplique transformações geométricas que criem amostras fisicamente impossíveis no domínio real.

2. Aumentações de Cor & Luz

Fotometria

```
ColorJitter(brightness=0.2, contrast=0.2)
RandomGrayscale(p=0.1)
GaussianBlur(kernel_size=3)
```

✓ Quando é Benéfico:

Força a rede neural a extrair contornos e morfologia geométrica em vez de confiar cegamente em condições de iluminação do sensor.

⚠ Risco de Corrupção Semântica:

Destrutivo quando a cor é o atributo discriminante primário (ex: semáforos verde/vermelho, colorações histológicas específicas ou espécies de plantas).

Regra: Verifique se a cor é decorativa (iluminação) ou estrutural (regrada pela classe).

3. Normalização Estatística

ImageNet Matching

```
Normalize(
    mean=[0.485, 0.456, 0.406],
    std=[0.229, 0.224, 0.225]
)
```

• Racional Matemático:

Os pesos convolucionais de modelos pré-treinados foram otimizados assumindo entradas com média zero e variância unitária sob esta distribuição específica.

• Omissão de Normalização:

Passar tensores em [0.0, 1.0] sem normalizar gera saturação precoce nas ativações ReLU das primeiras camadas, degradando a convergência.

💡 Sempre aplique a mesma normalização utilizada durante o pré-treinamento do backbone.



Avaliação Multiclasse: A Desagregação da Acurácia Global e a Acurácia por Classe

Decomposição matemática de métricas e o mascaramento de classes minoritárias

MÉTRICAS & DIAGNÓSTICO

Avaliação Multiclasse: A Desagregação da Acurácia Global e a Acurácia por Classe

Acurácia Ilusória

Acurácia por Classe

Balanced Accuracy

Decomposição Formal das Métricas

Acurácia Global:

$$Acc_{global} = \frac{\sum_{c=1}^C TP_c}{\sum_{c=1}^C N_c}$$

Acurácia da Classe c:

$$Acc_c = \frac{TP_c}{N_c}$$

Balanced Accuracy:

$$B-Acc = \frac{1}{C} \sum_{c=1}^C Acc_c$$

Exemplo Real de Mascaramento Estatístico (4 Classes):

Classe	Amostras (N)	Acertos (TP)	Acurácia por Classe	Diagnóstico
Classe 1 (Majoritária)	1.200	1.176	98.0%	Excelente
Classe 2	300	240	80.0%	Bom
Classe 3 (Rara)	100	30	30.0%	Crítico
Classe 4 (Muito Rara)	50	10	20.0%	Crítico

Acurácia Global Média:

88.2%

Parece excelente, mas mascara o colapso!

Balanced Accuracy Real:

57.0%

Média não-ponderada penaliza o fracasso

O Papel Mandatório da Matriz de Confusão

Auditoria Direcional

A matriz de confusão não informa apenas quantos erros ocorreram, mas **onde** o classificador está se confundindo:

1. Confusão Simétrica vs Assimétrica:

Identifica se a Classe A é confundida com a Classe B de forma recíproca ou se o modelo tem forte tendência unidirecional para a classe com mais amostras.

2. Análise de Custo Operacional:

Em aplicações reais, classificar uma peça com defeito como 'perfeita' possui custo financeiro ou de risco ordens de magnitude maior que o erro oposto.

3. Guia para Data Augmentation:

Se a Classe 3 for sistematicamente confundida com a Classe 1, foca-se o aumento de dados e a regularização especificamente na fronteira dessas duas classes.

 **Requisito Acadêmico:** Sempre reporte a acurácia global acompanhada obrigatoriamente da acurácia por classe e curvas de loss/epoch.

O Paradoxo da Acurácia sob Desbalanceamento Severo e a Primazia do Recall

Por que previsões triviais atingem 95% de acurácia global e causam falhas catastróficas em produção

REVISÃO TEÓRICA IV

O Paradoxo da Acurácia sob Desbalanceamento Severo e a Primazia do Recall

Paradoxo da Acurácia

Recall / Sensibilidade

F1-Macro

1. A Armadilha da Acurácia Global

Colapso Trivial

Considere um conjunto de teste com **1.000 amostras**: 900 são da classe comum (90%) e 100 são da classe rara/crítica (10%).

Classificador Degenerado (Prediz Sempre Classe Majoritária):

Acurácia Global:

90.0%

Parece "promissor"

Recall da Classe Rara:

0.0%

Ignora 100% dos casos!

💡 **Impacto Operacional & Clínico:** O modelo é estatisticamente inútil e perigoso. Todos os 100 casos raros tornam-se **Falsos Negativos (FN)**, passando despercebidos.

Em qualquer sistema onde o custo do Falso Negativo supera o Falso Positivo, a acurácia global é uma métrica inteiramente descabida.

⚠️ **Alerta Técnico:** Equipes ingênuas encerram projetos reportando 90%+ de acurácia sem perceber que o Recall da classe crítica é nulo.

2. Métricas Diagnósticas Obrigatórias

Governança Técnica

Sensibilidade / Recall (Taxa de Verdadeiros Positivos):

$$\text{Recall} = \frac{TP}{TP+FN}$$

Mede a capacidade do modelo de capturar todos os eventos críticos. Denominador inclui os casos omitidos (FN).

Precisão (Valor Preditivo Positivo):

$$\text{Precision} = \frac{TP}{TP+FP}$$

Fração de alarmes emitidos pelo modelo que realmente correspondiam a casos verdadeiros.

Especificidade:

$$\text{Especificidade} = \frac{TN}{TN+FP}$$

Taxa de identificação correta dos casos negativos (ausência de alarmes falsos).

F1-Score (Média Harmônica):

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Penaliza modelos com desequilíbrio entre Precisão e Recall. Se o Recall for zero, o F_1 é estritamente zero!

🎯 **Regra de Governança:** Modelos de triagem e alto risco devem ser otimizados visando maximizar o Recall da classe minoritária.

Estratégias Generativas (cGAN & CycleGAN) e o Protocolo Científico de Avaliação Downstream

Protocolo rigoroso de ampliação de classes raras e validação estrita em conjuntos de teste reais

MITIGAÇÃO GENERATIVA & PROTOCOLO

Estratégias Generativas (cGAN & CycleGAN) e o Protocolo Científico de Avaliação Downstream

cGAN / CycleGAN

Teste 100% Real

 Δ Recall Downstream

1. Abordagens Generativas para Escassez de Amostras

Quando técnicas tradicionais de rotação e flip não trazem diversidade suficiente para a classe rara:

Abordagem A: GAN Condicional (cGAN)

Oversampling Direcionado

$$G(z, y_{\text{rara}}) \in \mathbb{R}^{C \times H \times W} \quad \text{onde } y = \text{classe minoritária}$$

Injeta o rótulo da classe rara no gerador e discriminador. O modelo aprende a variedade interna da classe minoritária e gera amostras sintéticas sob demanda para equilibrar o lote.

Abordagem B: CycleGAN (Tradução Não-Pareada)

Transferência de Domínio

$$\mathcal{L}_{\text{cyc}}(G, F) = \mathbb{E}_x[\|F(G(x)) - x\|_1] + \mathbb{E}_y[\|G(F(y)) - y\|_1]$$

Converte imagens de uma classe abundante (X) para a aparência/estilo da classe rara (Y), preservando a morfologia estrutural através do ciclo bidirecional.

💡 Ambas as soluções geram dados no espaço contínuo de pixels sem exigir pares alinhados.

2. Protocolo Científico Mandatário

Validação Blindada

Para comprovar tecnicamente a utilidade dos dados sintéticos, deve-se seguir estritamente o protocolo experimental:

Regra 1 Injeção Exclusiva no Treinamento:

As imagens geradas por GAN entram **única e exclusivamente** no conjunto de treino ($D_{\text{train}} = D_{\text{real}} \cup D_{\text{sint}}$).

Regra 2 Conjunto de Teste 100% Real e Intocado:

O conjunto de teste **NUNCA** pode conter imagens sintéticas! Avaliar em imagens geradas é uma falha metodológica que invalida a pesquisa.

Regra 3 Métrica de Sucesso: Ganho de Recall:

$$\Delta \text{Recall} = \text{Recall}_{\text{com GAN}} - \text{Recall}_{\text{sem GAN}}$$

A GAN é bem-sucedida se, e somente se, elevar a Sensibilidade no teste real sem colapsar a Precisão.

📊 Comparativo Obrigatório: Compare duas curvas de aprendizado: Treino Base (sem GAN) vs Treino Aumentado (com GAN).



Armadilhas Metodológicas em Visão: Divisão Estratificada, Vazamento por Grupos e Domain Shift

Os três erros de protocolo mais comuns que invalidam sistemas em ambiente de produção

METODOLOGIA & GOVERNANÇA

Armadilhas Metodológicas em Visão: Divisão Estratificada, Vazamento por Grupos e Domain Shift

Stratified Split

Vazamento por Grupo

Covariate Shift

1. Divisão Estratificada

Preservação Proporcional

Em datasets com classes raras (ex: 5% a 10%), uma divisão aleatória ingênua (`train_test_split` sem estratificação) introduz forte variância estocástica:

❌ **Divisão Aleatória Pura:** Risco severo de alocar quase nenhuma amostra da classe minoritária no conjunto de teste, inviabilizando o cálculo do Recall.

✅ **Divisão Estratificada (Stratified):** Garante que Treino, Validação e Teste contêm exatamente a mesma proporção percentual de cada classe.

```
train_test_split(..., stratify=y, test_size=0.2)
```

2. Vazamento de Dados por Grupo

Data Leakage Crítico

O erro metodológico mais devastador em visão computacional:

• A Falha:

Sortear frames de vídeo consecutivos, imagens da mesma câmera ou do mesmo paciente entre treino e teste.

• A Ilusão:

A rede decora o fundo, a iluminação do dia ou a textura da câmera, atingindo 98% de acurácia em validação.

• A Solução: GroupKFold

Particionar estritamente por ID de Câmera, Sessão ou Paciente. A câmera do teste nunca deve ter sido vista no treino!

⚠️ Se o ambiente for idêntico no teste, você não está medindo inteligência, mas memorização de fundo!

3. Mudança de Distribuição (Shift)

Out-of-Distribution

Por que modelos bem avaliados no laboratório colapsam após o deploy em produção real:

• Covariate Shift $P(X)$:

A distribuição de entrada muda drasticamente: chuva, noite, névoa, poeira na lente ou novos ângulos de câmera não presentes no dataset.

• Discrepância de Resolução e Sensor:

Câmeras analógicas de baixa qualidade produzem ruído de compressão que corrompe as features extraídas de modelos ImageNet de alta definição.

🛡️ **Remediação:** Teste de estresse em conjuntos OOD intencionalmente degradados (ruído, iluminação adversa).

Laboratório Interativo: Quiz de Fixação da Disciplina

Avalie seus conhecimentos consolidados em avaliação generativa, transformers, multimodalidade e governança

QUIZ DE FIXAÇÃO

Consolidação dos Conceitos Fundamentais da Disciplina

Acertos: 0 / 5 **1** 2 3 4 5

Questão 1 de 5 • Avaliação de GANs & FID

Pós-Graduação EAD • Infnet

Ao calcular o FID de uma GAN, observou-se que o termo $\|\mu_r - \mu_g\|^2$ foi muito baixo (1.2), porém o termo de covariância $\text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$ resultou em um valor altíssimo (94.8), elevando o FID para 96.0. Qual é o diagnóstico técnico correto?

- A** O modelo sofreu mode collapse severo: capta a média global do domínio, mas perdeu a variabilidade/dispersão interna das features.
- B** A taxa de aprendizado do discriminador foi baixa, fazendo o gerador criar imagens com viés sistemático de cor e brilho.
- C** O Inception-v3 falhou na extração de características devido ao uso de interpolação bilinear no pré-processamento.
- D** As imagens geradas possuem alta frequência de ruído estocástico que deslocou o centroide da distribuição.

[← Questão Anterior](#)

Navegue para revisar os 5 pilares do projeto da disciplina

[Próxima Questão →](#)